SemRel2024: Bộ sưu tập dữ liệu về mối liên hệ ngữ nghĩa giữa các văn bản cho 13 ngôn ngữ

Nedjma Ousidhoum, Shamsuddeen Hassan Muhammad, Mohamed Abdalla, Idris Abdulmumin, Ibrahim Said Ahmad, Sanchit Ahuja, Alham Fikri Aji, Vladimir Araujo , Abinew Ali Ayele , Pavan Baswani, Meriem Beloucif, Chris Biemann, Sofia Bourhim, Christine De Kock, Genet Shanko Dekebo, Oumaima Hourrane, Gopichand Kanumolu, Lokesh Madasu, Samuel Manish Shrivastava, Thamar Solorio, Nirmal Surange, Hailegnaw Getaneh Tilaye, Krishnapriya Vishnubhotla, Genta Winata, Seid Muhie Yimam, Saif M. Moham

1.Đại học Cardiff , 2 Đại học Imperial College London, Nhóm nghiên cứu Khoa học Dữ liệu vì Tác động Xã hội, Đại học Pretoria,4 Viện Trí tuệ Nhân tạo Trải nghiệm, Đại học Northeastern, 5 BITS Pilani, 6 MBZUAI, 7 KU Leuven, 8 Đại học Hamburg, Nhóm Công nghệ Ngôn ngữ, 9 Đại học Bahir Dar, Khoa Máy tính, 10 IIIT Hyderabad, 11 Đại học Uppsala, 12 Đại học Melbourne, 13 Đại học Khoa học và Công nghệ Adama, 14 Digital Umuganda, 15 Đại học Sư phạm Kotebe, 16 Đại học Toronto, 17 Đại học Khoa học và Công nghệ Hồng Kông (HKUST), 18 Hội đồng Nghiên cứu Quốc gia Canada

Liên hệ: OusidhoumN@cardiff.ac.uk

Tóm tắt (Abstract)

Việc khám phá và định lượng mức độ liên quan ngữ nghĩa đóng vai trò trung tâm trong biểu diễn ngôn ngữ và có ảnh hưởng lớn đến nhiều bài toán trong xử lý ngôn ngữ tự nhiên (NLP). Trong khi các nghiên cứu NLP trước đây chủ yếu tập trung vào độ tương đồng ngữ nghĩa (semantic similarity), thường chỉ trong bối cảnh tiếng Anh, thì trong công trình này chúng tôi nghiên cứu khái niệm rộng hơn là mức độ liên quan ngữ nghĩa (semantic relatedness).

Chúng tôi giới thiệu SemRel, một bộ sưu tập dữ liệu mới về mức độ liên quan ngữ nghĩa, được gán nhãn bởi người bản ngữ cho 13 ngôn ngữ: Afrikaans, tiếng Ả Rập Algeria, Amharic, tiếng Anh, Hausa, Hindi, Indonesia, Kinyarwanda, Marathi, tiếng Ả Rập Morocco, tiếng Ả Rập Chuẩn Hiện đại, Tây Ban Nha và Telugu. Các ngôn ngữ này thuộc năm họ ngôn ngữ khác nhau và chủ yếu được sử dụng tại châu Phi và châu Á - những khu vực còn thiếu tài nguyên NLP.

Mỗi mẫu trong bộ dữ liệu SemRel là một cặp câu, đi kèm với một điểm số biểu thị mức độ liên quan ngữ nghĩa giữa hai câu. Các điểm số này được thu thập bằng khuôn khổ gán nhãn so sánh. Bài báo mô tả chi tiết quá trình thu thập và gán nhãn dữ liệu, các thách thức trong việc xây dựng bộ dữ liệu, các thí nghiệm cơ sở (baseline), cũng như giá trị và tác động của bộ dữ liệu đối với NLP.

1. Giới thiệu (Introduction)

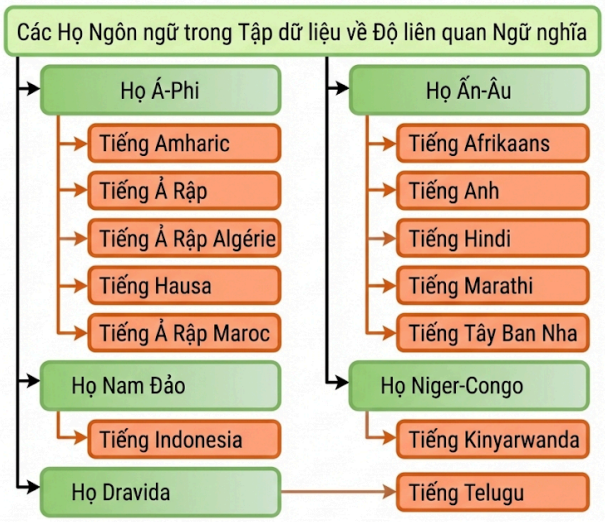

Figure 1: SemRel2024 languages and language families.

Hình 1: Các ngôn ngữ trong SemRel2024 và các họ ngôn ngữ tương ứng.

Việc đặc trưng hóa mối quan hệ giữa hai đơn vị văn bản là một thành phần quan trọng trong việc xây dựng các biểu diễn văn bản. Trong bối cảnh này, mức độ liên quan ngữ nghĩa văn bản (*Semantic Textual Relatedness - STR*) nhằm nắm bắt mức độ mà hai đơn vị ngôn ngữ (ví dụ: từ, câu, v.v.) gần nhau về mặt ý nghĩa (Mohammad, 2008; Mohammad và Hirst, 2012).

Hai đơn vị văn bản có thể liên quan với nhau theo nhiều cách khác nhau, chẳng hạn như cùng thể hiện một quan điểm, xuất phát từ cùng một giai đoạn thời gian, hoặc bổ sung, diễn giải cho nhau, v.v. Ngược lại, độ tương đồng ngữ nghĩa văn bản (*Semantic Textual Similarity - STS*) chỉ xem xét một phạm vi hẹp hơn của mối quan hệ có thể tồn tại giữa các văn bản (chẳng hạn như tương đương về nghĩa hoặc diễn đạt lại/paraphrase), và không bao gồm các chiều cạnh khác của mối liên quan như suy diễn ngữ nghĩa (entailment), tương đồng về chủ đề hoặc quan điểm, hay mối quan hệ về thời gian (Abdalla et al., 2023; Agirre et al., 2013a).

Ví dụ, hai câu *"Tôi bị cảm lạnh."* và *"Tôi hy vọng bạn sớm khỏe lại."* sẽ nhận điểm tương đồng thấp, mặc dù hai câu này rất liên quan với nhau về mặt ngữ nghĩa. Trong nghiên cứu này, chúng tôi tập trung khảo sát khái niệm rộng hơn là mức độ liên quan ngữ nghĩa văn bản.

STR đóng vai trò trung tâm trong việc hiểu ý nghĩa của văn bản (Hasan và Halliday, 1976; Miller và Charles, 1991; Morris và Hirst, 1991), và việc tự động hóa STR có thể mang lại lợi ích cho nhiều bài toán xử lý ngôn ngữ tự nhiên ở tầng ứng dụng, chẳng hạn như đánh giá các phương pháp biểu diễn câu, hỏi - đáp, và tóm tắt văn bản (Abdalla et al., 2023; Wang et al., 2022).

Lang.	Sentence 1	Sentence 2	Score
tel	ఇప్పటికే ధోనీ టెస్టు క్రికెట్ కు గుడ్ బై చెప్పిన విషయం తెలిసిందే.	అంతకు ముందు జరిగిన మరో రోడ్డు ప్రమాదంలో ఏడుగురు మరణించగా, 12 మంది గాయపడ్డారు.	0.02
afr	My eerste stukkie advies is dat jy realisties moet wees oor die afstand wat jy wil hengel.	Dit bring tot n einde die maan-verkenningsprogram van die Verenigde State..	0.19
esp	Costo monetario para mantener el microondas por $6.	Todavía nos quedan más de 200.000$ por recaudar de suscriptores y donantes como usted.	0.27
mar	ठाकरे सरकारच्या मंत्रिमंडळात 25 कॅबिनेट मंत्री असणार आहेत.	त्यामुळे गुढी पाडवा मेळाव्यामध्ये राज ठाकरे काय बोलणार याकडे सर्वांचे लक्ष लागून राहिले आहे.	0.42
arq	كاين واحد الأبيات يقولهم في الغنى تاعو تكوني تعرفيهم	اللي ما زهاش في الدنيا من الروح خالي	0.50
arb	الآن انتقل بكم إلى لمحة عن تاريخ الاقتصاد و في نظري قد تكون مفيدة.	حوالي عام ١٨٥٠ كان صيد الحيتان من أكبر الصناعات في الولايات المتحدة	0.62
hin	देश में कोरोना वायरस से मौत का आंकड़ा 100 के पार पहुंचा, पिछले 12 घंटे में 26 की गई जान.	देश में कोरोना वायरस का कहर तेजी से बढ़ता जा रहा है।	0.72
kin	Duhugukire kwandika neza Ikinyarwanda Mu myandikire yIkinyarwanda hari amakosa akunda gukorwa ashingiye ku ifatana nitandukana ryamagambo.	Duhugukire kwandika neza Ikinyarwanda (igice cya gatatu) Mu myandikire yIkinyarwanda, hari amagambo afatana nandi atandukana.	0.75
ary	وجدو راسكوم لرمضان.. الحرارة غادي تبدا بـ٣٧ درجة فهاد المناطق	غير خرج رمضان وهي تشعل.. الحرارة غادي تبدا وغادي توصل لـ٤٠ درجة فهاد المناطق	0.75
ind	Pendidikan Desa Pusaka memiliki 4 sekolah.	Pendidikan Desa Serumpun Buluh memiliki 4 sekolah.	0.83
amh	**እኛን ከዚህ ጉዳይ ጋር የምንገናኝበት ቅንጣት ታክል ግንኙነት የለም**	**እኛን ቅንጣት ታህል ከዚህ ጉዳይ ጋ የሚያገናኘን ነገር የለም**	0.89
hau	Haka ya furta a cikin jawabin sa na murnar cikar Najeriya shekaru 61 da samun yanci.	Ya yi wannan iirarin e a cikin jawabin sa na murnar cikar Najeriya 61 da samun yanci a ranar Jumaa.	0.94
eng	I've been searching the entire abbey for you.	I'm looking for you all over the abbey.	1.00

Bảng 1: Ví dụ về các cặp câu và điểm số tương ứng (từ 0 đến 1) trong các ngôn ngữ SemRel2024 khác nhau. Các ví dụ được sắp xếp theo điểm số và các hàng có mức độ liên quan cao hơn được tô màu nhạt hơn. Bản dịch có thể được tìm thấy trong Phụ lục.

Các nghiên cứu NLP trước đây chủ yếu tập trung vào độ tương đồng văn bản, phần lớn là do thiếu các bộ dữ liệu về mức độ liên quan. Trong số các bộ dữ liệu STR và STS hiện có, hầu hết đều bằng tiếng Anh. Một số ít tài nguyên STR và STS tồn tại cho các ngôn ngữ không có nhiều tài nguyên được cấu thành từ các cặp ở mức từ hoặc mức cụm từ. Trong nghiên cứu này, chúng tôi tuyển chọn 13 bộ dữ liệu STR đơn ngữ mới[1] cho các ngôn ngữ: Afrikaans (afr), Amharic (amh), tiếng Ả Rập Chuẩn Hiện đại (arb), tiếng Ả Rập Algeria (arq), tiếng Ả Rập Morocco (ary), tiếng Anh (eng), tiếng Tây Ban Nha (esp), tiếng Hausa (hau), tiếng Hindi (hin), tiếng Indonesia (ind), tiếng Kinyarwanda (kin), tiếng Marathi (mar), và tiếng Telugu (tel).

Các bộ dữ liệu được cấu thành từ các cặp câu, mỗi cặp được gán một điểm số liên quan giữa 0 (hoàn toàn không liên quan) và 1 (liên quan tối đa).

[1]Nhóm nghiên cứu của chúng tôi cũng tạo dữ liệu cho tiếng Punjabi. Tuy nhiên, quy trình chọn cặp câu cho ngôn ngữ này khác biệt đáng kể so với những gì chúng tôi sử dụng cho các ngôn ngữ khác. Do đó chúng tôi không đưa nó vào đây.

Với mục tiêu tuyển chọn các bộ dữ liệu STR đa dạng, các cặp câu đầu tiên được chọn từ các bộ dữ liệu có sẵn trước đó bao gồm nhiều chủ đề và mức độ trang trọng khác nhau, ví dụ: dữ liệu tin tức, Wikipedia và dữ liệu hội thoại. Ngoài ra, chúng tôi đã chọn các cặp có phạm vi giá trị liên quan dự kiến rộng bằng cách xem xét sự trùng lặp từ vựng, tính liền kề, phạm vi chủ đề và việc ghép cặp ngẫu nhiên. Để tạo ra các điểm số liên quan, các cặp câu sau đó được chú thích bởi những người bản ngữ thực hiện so sánh giữa các cặp câu khác nhau sử dụng phương pháp Best-Worst Scaling (BWS) (Louviere và Woodworth, 1991). BWS được biết đến là tránh được các hạn chế phổ biến của các phương pháp chú thích theo thang điểm truyền thống (Kiritchenko và Mohammad, 2016, 2017). Quá trình chú thích đã dẫn đến độ tin cậy cao của các thứ hạng liên quan cuối cùng trong các bộ dữ liệu SemRel khác nhau. Những đóng góp chính của chúng tôi như sau:

1. Chúng tôi trình bày bộ chuẩn đánh giá đầu tiên về khoảng cách ngữ nghĩa (tương tự hoặc liên quan) bao gồm các ngôn ngữ châu Phi và châu Á có nguồn tài nguyên thấp từ năm nhóm ngôn ngữ khác nhau (xem Hình 1). Mặc dù Châu Phi và Châu Á là nơi có hơn 5.000 ngôn ngữ từ hơn 20 họ ngôn ngữ và có sự đa dạng ngôn ngữ cao nhất, hiện có rất ít dữ liệu được công bố công khai cho các ngôn ngữ này.

2. Chúng tôi thảo luận về những thách thức chung và thách thức cụ thể liên quan đến ngôn ngữ trong việc thu thập và chú thích dữ liệu của bộ dữ liệu SemRel.

3. Chúng tôi trình bày các thí nghiệm cơ bản đã được tiến hành trong các bối cảnh đơn ngữ và đa ngữ khác nhau để chứng minh tính hữu ích và tiềm năng của bộ dữ liệu mà chúng tôi đã thu thập

Để thúc đẩy nghiên cứu trong lĩnh vực liên quan ngữ nghĩa, chúng tôi đã công bố công khai các bộ dữ liệu SemRel2024 như một phần của nhiệm vụ chung, thu hút một số lượng lớn người tham gia quan tâm đến các ngôn ngữ có nguồn tài nguyên thấp.

2. Công trình nghiên cứu liên quan

Lĩnh vực liên quan ngữ nghĩa trong xử lý ngôn ngữ tự nhiên bao gồm nhiều cách tiếp cận khác nhau và các kỹ thuật được thiết kế để đo lường sự gần gũi về nghĩa giữa các đơn vị, cụ thể là các từ (Miller, 1994) hoặc các câu (Abdalla và cộng sự, 2023). Hầu hết các nghiên cứu trước đây đều tập trung vào STS, một tập hợp con hẹp hơn của STR, và thường chỉ bao gồm các ngôn ngữ có nguồn tài nguyên cao như tiếng Anh (Agirre và cộng sự, 2012, 2013b, 2014, 2015, 2016; Marelli và cộng sự, 2014), tiếng Ả Rập, tiếng Đức, tiếng Tây Ban Nha, tiếng Thổ Nhĩ Kỳ (Ahmed và cộng sự, 2020; Cer và cộng sự, 2017b) và tiếng Ý (Glavaš và cộng sự, 2018), với ngoại lệ duy nhất là tiếng Phần Lan, tiếng Slovenia, tiếng Croatia (Glavaš và cộng sự, 2018; Armendariz và cộng sự, 2020) và tiếng Farsi (Vulić và cộng sự, 2020). Để vượt qua sự khan hiếm các nguồn lực sẵn có, Tang và cộng sự (2018) đề xuất các phương pháp dựa

trên bộ mã hóa ở cấp độ câu, tận dụng dữ liệu tiếng Anh để tạo các bộ dữ liệu tiếng Ả Rập, tiếng Tây Ban Nha, tiếng Thái và tiếng Indonesia, trong khi Pandit và cộng sự (2019) sử dụng các phương pháp tăng cường dữ liệu truyền thống để tạo dữ liệu tiếng Bangla.

Để so sánh, công trình này tập trung vào việc tạo ra các tài nguyên cho STR ở cấp độ câu trong môi trường đa ngôn ngữ với nhiều ngôn ngữ có nguồn tài nguyên thấp. Ở đây, số ít các nghiên cứu tồn tại cho các ngôn ngữ có nguồn tài nguyên thấp chủ yếu ở cấp độ từ (ví dụ: Yum và cộng sự, 2021 đối với tiếng Hàn).

Theo hiểu biết của chúng tôi, tập tài liệu duy nhất được thiết kế đặc biệt cho mối liên hệ văn bản ngữ nghĩa giữa các cặp câu được tạo ra bởi Abdalla và cộng sự (2023) cho tiếng Anh. Abdalla và cộng sự (2023) đã tuyển chọn một tập dữ liệu gồm 5.500 cặp câu tiếng Anh có chú thích, sử dụng khung chú thích so sánh. Tập dữ liệu của họ sau đó đã được sử dụng để đánh giá các phương pháp nhúng (Wang và Li, 2022) và các phương pháp khác (Wang và cộng sự, 2022). Cốt lõi trong cách tiếp cận của Abdalla và cộng sự (2023) đóng vai trò là mô hình cho việc chú thích dữ liệu trong dự án này. Tuy nhiên, công trình của chúng tôi bổ sung thêm bằng việc khám phá những cách thức mới để thu thập và quản lý dữ liệu, đồng thời giải quyết một số thách thức phát sinh khi làm việc với các ngôn ngữ có nguồn tài nguyên thấp hơn.

3. Dữ Liệu STR

3.1 Thu thập dữ liệu

Một bước quan trọng trong quy trình xử lý dữ liệu là xác định và lựa chọn nguồn văn bản cho từng ngôn ngữ, cũng như chọn lọc các câu phù hợp. Công việc này đặc biệt khó khăn đối với các ngôn ngữ có nguồn tài nguyên thấp như tiếng Hausa, tiếng Kinyarwanda và tiếng Ả Rập Algeria. Việc lựa chọn và ghép câu một cách tùy tiện có thể dẫn đến dữ liệu kém chất lượng, do đó chúng tôi áp dụng các quy tắc heuristic được trình bày trong Mục 3.1.1 nhằm đảm bảo sự phân bố đa dạng của các mức điểm liên quan cho mỗi ngôn ngữ. Do các phương pháp này có tính đặc thù cao đối với từng ngữ liệu và ngôn ngữ, cách tiếp cận được sử dụng cho mỗi ngôn ngữ đều được xác định bởi người bản ngữ. Chúng tôi cung cấp nguồn gốc dữ liệu và các phương pháp ghép câu được áp dụng cho từng ngôn ngữ trong Mục 3.1.2. Thành phần của tập dữ liệu kết quả được tóm tắt trong Bảng 6, trong khi phân bố điểm liên quan trên các tập dữ liệu được minh họa trong Hình 2.

3.1.1 Nguyên tắc ghép cặp câu

Với một tập văn bản trong ngôn ngữ mục tiêu, việc xây dựng cẩn thận các cặp câu được xem xét kỹ lưỡng để đảm bảo các cặp câu có điểm liên quan trải dài từ hoàn toàn không liên quan đến rất liên quan. Vì việc chọn ngẫu nhiên sẽ tạo ra nhiều cặp không liên quan, chúng tôi chủ yếu ghép cặp câu dựa trên năm phương pháp đã được Abdalla và cộng sự (2023) định nghĩa trước đó (được mô tả bên dưới). Trong những trường hợp các cặp câu tạo ra bởi năm phương pháp này bị đánh giá về mặt chất lượng là không đủ đa dạng, chúng tôi đã chọn thủ công một

số trường hợp để cân bằng dữ liệu, nhằm đảm bảo có đủ số lượng mẫu cho mỗi mức độ liên quan (cao, trung bình, thấp hoặc không liên quan).

Xem tại https://semantic-textual-relatedness.github.io để biết thêm chi tiết

Ngôn ngữ	Kỹ thuật chọn câu	Nguồn dữ liệu
afr	Trùng lặp, chọn ngẫu nhiên, kiểm tra thủ công	Tin tức, đánh giá, công thức, blog
amh	Trùng lặp, tương đồng, chọn ngẫu nhiên, kiểm tra thủ công	Tin tức, thu thập web
arb	Trùng lặp, liền kề, chọn ngẫu nhiên, kiểm tra thủ công	Phụ đề TED Talk, tin tức
arq	Trùng lặp, liền kề, chọn ngẫu nhiên, kiểm tra thủ công	Bình luận YouTube, dữ liệu hội thoại
ary	Trùng lặp	Tin tức
eng	Trùng lặp, tương đồng, diễn giải lại, liền kề, ngẫu nhiên	Đánh giá sách, tin tức, tweet, nguồn khác
esp	Trùng lặp, liền kề, tương đồng	Đánh giá phim, tin tức, nguồn khác
hau	Trùng lặp	Tin tức
hin	Trùng lặp, tương đồng, liền kề, diễn giải lại, ngẫu nhiên	Tin tức, nguồn khác
ind	Trùng lặp	Wikipedia, tin tức
kin	Trùng lặp	Tin tức
mar	Trùng lặp, tương đồng, liền kề, diễn giải lại, ngẫu nhiên	Tin tức, nguồn khác
tel	Trùng lặp, tương đồng, liền kề, diễn giải lại, ngẫu nhiên	Tin tức, nguồn khác

Bảng 2: Các kỹ thuật tuyển chọn (curation) được sử dụng để tạo dữ liệu.Chúng tôi liệt kê các nguồn văn bản chính có trong các bộ dữ liệu được sử dụng để tạo các ví dụ (instance). Chi tiết hơn được trình bày trong Mục 3.1.2.

Trùng lặp từ vựng Các cặp được chọn với các mức độ trùng lặp từ vựng khác nhau. Nghĩa là có một hoặc nhiều từ/tokens chung, có hoặc không sử dụng chuẩn hóa TF-IDF. Phương pháp này được kỳ vọng tạo ra một dải giá trị liên quan rộng, và được sử dụng ở hầu hết các ngôn ngữ tài nguyên thấp.

Liền kề/Ngụ ý: Chúng tôi chọn các cặp câu xuất hiện liên tiếp nhau trong một đoạn văn hoặc một chuỗi mạng xã hội. Phương pháp này có khả năng tạo ra các cặp câu có liên quan phần nào và có thể góp phần đại diện cho các mức liên quan từ thấp đến trung bình.

Diễn giải lại hoặc Dịch máy: Phương pháp này bao gồm việc chọn các cặp câu từ dữ liệu diễn giải lại hoặc dịch máy. Đối với dịch máy, chúng tôi dịch chéo qua bản dịch và dịch ngược trở lại ngôn ngữ nguồn để tạo một câu mới và ghép nó với câu gốc. Tuy nhiên, nhiều ngôn ngữ châu Á và châu Phi có tài nguyên thấp thiếu các nguồn dịch máy đáng tin cậy.

Các mẫu tương đồng ngữ nghĩa: Các câu tương đồng ngữ nghĩa được chọn từ một bộ dữ liệu công khai như bộ dữ liệu STS của Cer và cộng sự (2017a) hoặc được xác định thủ công bởi người bản ngữ nhằm bao gồm các mẫu có liên quan cao và cân bằng bộ dữ liệu.

Chọn ngẫu nhiên :Các câu được chọn ngẫu nhiên. Phương pháp này được kỳ vọng đại diện cho các mức liên quan từ thấp đến trung bình.

Kiểm tra thủ công : Trong trường hợp các cặp sản xuất bằng các phương pháp trên đã được đánh giá về mặt chất lượng không đủ đa dạng, các trường hợp đã được chọn thủ công để cân bằng dữ liệu sao cho có

đủ số lượng các trường hợp cho mỗi dải liên quan (cao, trung bình, thấp hoặc không liên quan). Cái này có thể áp dụng cho bất kỳ phạm vi liên quan nào (ví dụ: cao, trung bình, thấp hoặc không liên quan).

3.1.2. Quản lý dữ liệu

Vì hầu hết các ngôn ngữ trong SemRel đều là các ngôn ngữ có nguồn tài nguyên thấp, nên miền nội dung, mức độ hình thức và tính đa dạng của các cặp câu phụ thuộc rất nhiều vào các tập dữ liệu công khai sẵn có. Chúng tôi hướng tới việc thu thập một bộ dữ liệu gồm các câu có độ dài trung bình, không mang tính xúc phạm và có mức độ đa dạng cao nhất có thể. Do đó, các mẫu dữ liệu cho từng ngôn ngữ được trích xuất bằng cách sử dụng sự kết hợp phù hợp của các quy tắc heuristic được mô tả trong Mục 3.1.1. Ngoài ra, chúng tôi còn áp dụng các phương pháp tiền xử lý, hậu xử lý và phân tích dữ liệu (được thảo luận dưới đây) nhằm tránh sự thiếu mạch lạc và tính không tự nhiên.

Tiếng Anh và tiếng Tây Ban Nha. Vì tiếng Anh và tiếng Tây Ban Nha là các ngôn ngữ có nguồn tài nguyên cao, chúng tôi đã lấy mẫu các câu từ nhiều nguồn khác nhau để nắm bắt sự

đa dạng về cấu trúc câu, mức độ hình thức và ngữ pháp trong văn bản. Như thể hiện trong Bảng 6, chúng tôi ghép các câu theo nhiều cách khác nhau, bao gồm sự chồng chéo từ vựng, sự nối tiếp, sự tương đồng và diễn giải. Tập dữ liệu tiếng Anh bao gồm các câu có cùng nội dung ngữ nghĩa nhưng khác hình thức, được thu thập từ bộ dữ liệu Formality (Rao và Tetreault, 2018), các tweet (Mohammad và cộng sự, 2017), các câu diễn giải từ hệ thống dịch máy trích xuất từ bộ dữ liệu ParaNMT (Wieting và Gimpel, 2017), các bài đánh giá sách từ Goodreads (Wan và McAuley, 2018), các cặp tiền đề–giả thuyết từ bộ dữ liệu SNLI (Bowman và cộng sự, 2015) và các câu tương tự về mặt ngữ nghĩa (Cer và cộng sự, 2017a).

Tương tự, chúng tôi lựa chọn các cặp câu tiếng Tây Ban Nha

Ngôn ngữ	Afrikaans	Amharic	Ả Rập Chuẩn Hiện đại	Ả Rập Algeria	Ả Rập Ma-rốc	Tiếng Anh	Tây Ban Nha	Hausa	Hindi	Indonesia	Kinyarwanda	Marathi	Telugu
Số chú giải / mỗi bộ	2	4	2–3	2	2	2–4	2–4	2–4	4	2	2	2–3	4
SHR (huấn luyện / phát triển)	0.85	0.9	0.86	0.64	0.77	0.84	0.7	0.74	0.93	0.68	0.74	0.92	0.79
SHR (kiểm tra)	0.85	0.9	0.86	0.64	0.77	0.8	0.7	0.74	0.94	0.68	0.74	0.96	0.96

Bảng 3: Điểm số SHR (split-half reliability) cho từng phân chia tập dữ liệu và số lượng chú thích duy nhất cho mỗi tuple (#Ann/tuple). Vì một số ngôn ngữ (eng, hin, mar, và tel) có các phân chia được chú thích trong các nỗ lực chú thích riêng biệt (thay vì một chú thích kết hợp), chúng tôi báo cáo điểm số SHR cho cả hai.

từ các tập dữ liệu về độ tương đồng ngữ nghĩa như STS (Agirre et al., 2014, 2015; Cer et al., 2017a), các tập dữ liệu về suy diễn như SICK-es (Huertas-Tato et al., 2021) và NLI-es (Araujo et al., 2022), và các tập dữ liệu về diễn đạt lại như PAWS-X (Yang et al., 2019). Chúng tôi cũng lấy mẫu các câu liền kề từ XL-Sum (Hasan et al., 2021) và BSO DiscoEval Spanish (Araujo et al., 2022), và chúng tôi bao gồm các câu hỏi thuộc các loại khác nhau từ Spanish QC (Á. García Cumbreras et al., 2006).

Các biến thể tiếng Ả Rập: Tiếng Ả Rập Chuẩn Hiện đại, Ả Rập Algérie, và Ả Rập Maroc Tiếng Ả Rập nổi tiếng với hiện tượng song ngữ (diglossia) (Ferguson, 1959), nghĩa là các biến thể tiếng Ả Rập được sử dụng trong các ngữ cảnh khác nhau. Ví dụ, Tiếng Ả Rập Chuẩn Hiện đại thường được sử dụng trong giao tiếp trang trọng và học thuật, trong khi các phương ngữ thường dùng cho các tình huống trò chuyện. Các nguồn dữ liệu khác nhau của dữ liệu tiếng Ả Rập phần nào phản ánh các tình huống sử dụng ngôn ngữ riêng biệt này.

Do đó, đối với Tiếng Ả Rập Chuẩn Hiện đại (MSA), chúng tôi sử dụng hai tập dữ liệu từ các lĩnh vực khác nhau: phụ đề TED Talk (Zong, 2015) về khoa học, xã hội và nghệ thuật, và các bài báo tin tức về kinh tế (Al-Dulaimi, 2022). Ngoài các câu có sự chồng chéo từ vựng, chúng tôi chọn các câu liền kề trong phụ đề TED Talk để bao gồm các mức độ liên quan khác nhau, và vì một số câu trong phụ đề hơi không đúng ngữ pháp, chúng tôi đã sửa chúng dựa trên các quy tắc ngữ pháp tiếng Ả Rập chuẩn.

Đối với tiếng Ả Rập Algérie, chúng tôi sử dụng CalYou (Abidi et al., 2017), một tập dữ liệu gồm các bình luận YouTube được thu thập từ các kênh YouTube chính của Algérie đến năm 2017, và các trường hợp tiếng Ả Rập Algérie được nói ở hai thành phố lớn của Algérie (Algiers và Annaba) có trong PADIC: Parallel Arabic Dialect Corpus (Meftouh et al., 2015). Chúng tôi sử dụng sự chồng chéo từ vựng để ghép đôi các câu, chọn các câu liền kề trong một cuộc trò chuyện trong PADIC, và thêm các cặp câu được chọn ngẫu nhiên hoặc thủ công để cân bằng phân bố điểm liên quan trong tập dữ liệu. Đối với cả MSA và tiếng Ả Rập Algérie, chúng tôi cho phép các câu ngắn vì tiếng Ả Rập có tính biến hình cao.

Đối với tiếng Ả Rập Maroc, chúng tôi sử dụng các tiêu đề từ tập dữ liệu Goud.ma được giới thiệu bởi Issam và Mrini (2022) và các câu tiếng Ả Rập Maroc được ghép đôi dựa trên sự chồng chéo từ vựng.

Afrikaans Tập dữ liệu Oscar (Ortiz Suárez et al., 2020) được sử dụng làm cơ sở cho kho ngữ liệu tiếng Afrikaans. Chúng tôi chọn các câu từ các bài báo tin tức, blog, đánh giá và công thức nấu ăn. Chúng tôi cũng loại trừ các câu từ văn bản tôn giáo và bài báo học thuật sau khi quan sát thấy chúng không tạo ra các cặp chất lượng cao. Chúng tôi còn loại trừ một số văn bản quảng cáo dường như là bản dịch chất lượng thấp. Tất cả các trường hợp sau đó được đánh giá thủ công về ngữ pháp và các câu không đúng ngữ pháp được loại bỏ. Các câu được ghép đôi nếu chúng có sự chồng chéo ít nhất năm token và ít nhất ba token không chồng chéo với các khớp chỉ trong cùng một bài báo. Các cặp câu ngẫu nhiên cũng được bao gồm để hiệu chỉnh tập dữ liệu.

Amharic, Hausa, Kinyarwanda Đối với tiếng Amharic, chúng tôi ghép đôi các câu có trong các bài báo tin tức từ các cơ quan tin tức Ethiopia khác nhau (Yimam et al., 2021). Tương tự, các tập dữ liệu Hausa và Kinyarwanda bao gồm các cặp câu từ các bài báo tin tức được thu thập bởi Abdulmumin và Galadanci (2019) và Niyongabo et al. (2020), tương ứng. Các câu ngắn hơn năm từ và dài hơn 20 từ bị loại trừ, và các cặp được tạo bằng sự chồng chéo từ vựng. Ngoài ra, đối với tiếng Amharic, chúng tôi loại trừ các câu có ngôn ngữ hỗn hợp để tránh làm rối các annotator.

Indonesian Đối với tiếng Indonesia, chúng tôi thu thập các câu từ văn bản Wikipedia có trong phần ROOTS (Laurençon et al., 2022; Setya và Mahendra, 2018) và các tập dữ liệu IndoSum (Kurniawan và Louvan, 2018). IndoSum là một tập dữ liệu tóm tắt do con người viết gồm các cặp bài báo tin tức với các tóm tắt trừu tượng. Chúng tôi phân tích cả hai kho ngữ liệu ở cấp độ câu và chỉ chọn các câu gồm từ năm đến mười lăm từ.

Hindi, Marathi, và Telugu Vì các ngôn ngữ này thiếu tài nguyên công khai có sẵn, đặc biệt là Marathi và Telugu, chúng tôi chỉ sử dụng tập dữ liệu Mukhyansh (Madasu et al., 2023) để tạo các cặp câu. Nó gồm các tiêu đề tin tức và các bài báo tương ứng và đa dạng về bản chất. Chúng tôi tạo các trường hợp sử dụng sự chồng chéo từ vựng, tạo diễn đạt lại, chọn câu liền kề, và chọn câu ngẫu nhiên để cân bằng dữ liệu.

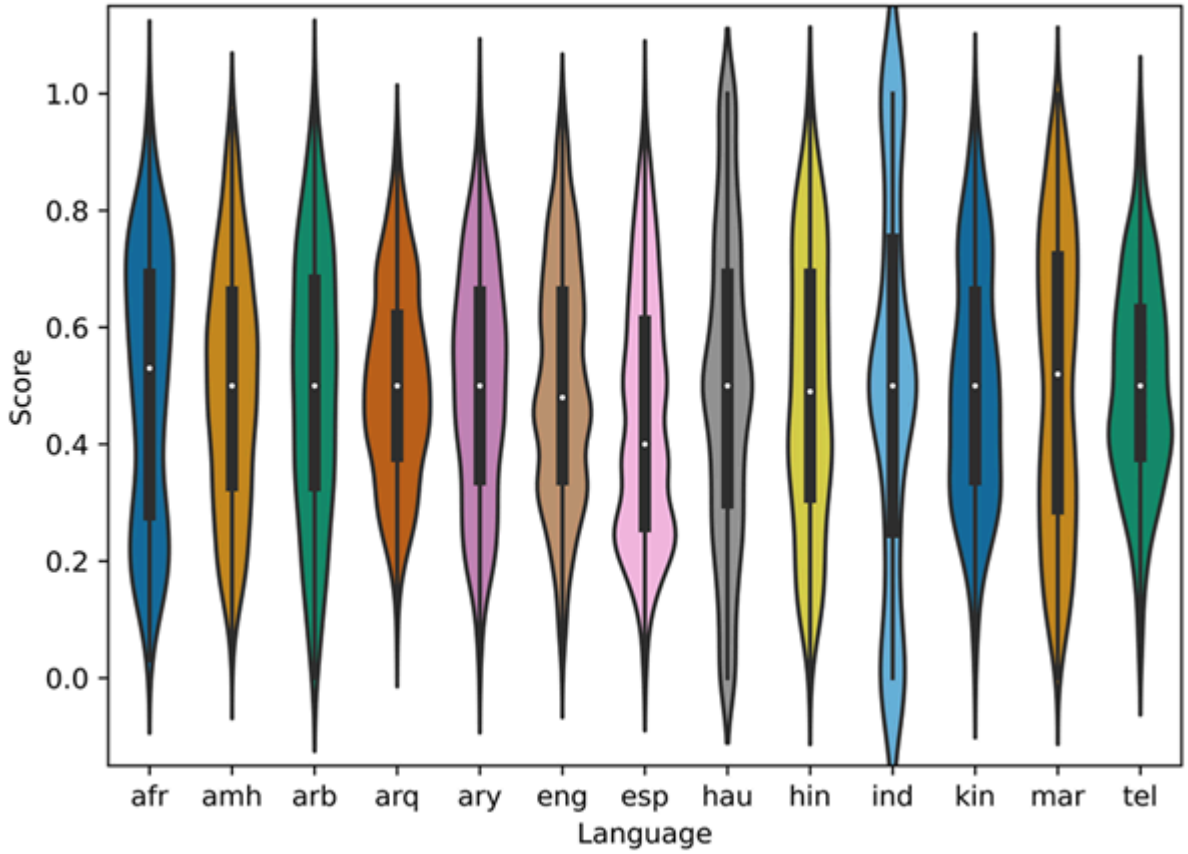

Hình 2: Các biểu đồ violin thể hiện phân bố của các điểm số liên quan.

Ví dụ, phân bố của tập dữ liệu tiếng Ả Rập (arb) là đơn cực (unimodal), của Marathi (mar) là lưỡng cực (bimodal), và của tập dữ liệu tiếng Indonesia (ind) là tam cực (trimodal).

3.2 Chú thích dữ liệu và các thách thức

Quy trình chú thích Tương tự như Abdalla và cộng sự (2023), chúng tôi sử dụng Best-Worst Scaling (BWS) để chú thích các trường hợp trong dữ liệu và tạo ra thứ hạng thứ tự (ordinal ranking) của các trường hợp[3].

Mặc dù việc so sánh từng cặp (pairwise comparisons) đáng tin cậy hơn so với việc chỉ đơn giản gắn nhãn các cặp câu là "liên quan" hoặc "không liên quan", nhưng đây là một quy trình tốn thời gian nếu thực hiện trên tập dữ liệu lớn, vì nó đòi hỏi $N \times N = N^2$ lần so sánh nếu áp dụng trên tập dữ liệu gồm N trường hợp.

Best-Worst Scaling giảm thiểu vấn đề này theo Kiritchenko và Mohammad (2017), vì nó cho phép tạo ra các điểm số đáng tin cậy chỉ từ khoảng $2 \times N$ lần so sánh trên các bộ bốn trường hợp (4-instance tuples).

BWS yêu cầu ít nhãn hơn (Louviere và Woodworth, 1991). Trong trường hợp của chúng tôi, với bốn trường hợp (tức là bốn cặp câu) pi với $0 \leq i < 4$, đối với một tuple: $\langle p_0, p_1, p_2, p_3 \rangle$, nếu p_0 được đánh dấu là **liên quan nhất** và p_3 là **ít liên quan nhất**, thì chúng ta biết rằng: $p_0 > p_1$, $p_0 > p_2$, $p_0 > p_3$, $p_1 > p_3$, và $p_2 > p_3$ (trong đó < và > lần lượt biểu thị "ít liên quan hơn" và "liên quan hơn").

Chúng tôi sau đó sử dụng các bất đẳng thức này để tính toán các **điểm số giá trị thực** (real-valued scores), được xác định là tỉ lệ số lần một cặp pi được chọn là liên quan nhất trừ đi tỉ lệ số lần pi được chọn là ít liên quan nhất. Từ đó, một **thứ hạng thứ tự** (ordinal ranking) của các cặp câu được tạo ra (Orme, 2009; Flynn và Marley, 2014).

[3]Các tuple được tạo bằng các script BWS do (Kiritchenko và Mohammad, 2017) cung cấp: http://saifmohammad.com/WebPages/BestWorst.html.

Hơn nữa, các khái niệm "liên quan" và "không liên quan" có ranh giới mơ hồ, không có định nghĩa duy nhất được chấp nhận trong tài liệu. Những người khác nhau và những nền văn hóa ngôn ngữ khác nhau có thể có nhiều trực giác khác nhau về vị trí tồn tại của ranh giới như vậy.

Do đó, bằng cách sử dụng chú thích so sánh và dựa vào trực giác của những người nói thông thạo từng ngôn ngữ để lựa chọn giữa các cặp câu, chúng tôi có thể tránh được các loại phân loại không được định nghĩa rõ ràng. Điều này phù hợp với mục tiêu của chúng tôi là nắm bắt các nhận thức phổ biến về liên quan ngữ nghĩa (tức là những gì được phần lớn tin tưởng) thay vì các thứ hạng "đúng" hoặc "phải".

Hướng dẫn Chúng tôi chọn người bản xứ để chú thích các cặp câu. Sau đó, với một bộ gồm bốn cặp câu, các annotator được giao nhiệm vụ báo cáo về mức độ liên quan tương đối của chúng. Cụ thể, với 4 cặp câu, mỗi cặp dưới dạng [câu A, câu B], nhiệm vụ là chọn cặp câu **liên quan nhất** (tức là câu A gần nghĩa nhất với câu B) và cặp câu **ít liên quan nhất** (tức là câu A xa nghĩa nhất với câu B). Hướng dẫn đầy đủ có thể tìm thấy trong Phụ lục.

Trong hướng dẫn, lưu ý rằng các cặp câu cụ thể hơn trong những gì chúng chia sẻ có xu hướng liên quan hơn so với các cặp câu chỉ lỏng lẻo về cùng chủ đề. Hơn nữa, nếu một hoặc cả hai câu có nhiều hơn một cách diễn giải, các annotator phải xem xét các nghĩa gần nhất.

Tổng thể, bằng cách kiểm tra thủ công các chú thích, chúng tôi nhận thấy rằng khung BWS thực sự dẫn đến các chú thích vững chắc hơn. Tuy nhiên, một nhược điểm là việc chú thích một trường hợp có thể mất hơn một phút và nhiệm vụ có thể thách thức vì nhiều trường hợp cần so sánh có thể tương tự nhau về mức độ (không) liên quan.

Độ tin cậy của chú thích (Annotation reliability)
Trong Bảng 3, chúng tôi báo cáo số lượng annotator và điểm số độ tin cậy chia đôi (split-half reliability - SHR) (Cronbach, 1951; Kuder and Richardson, 1937) cho từng bộ dữ liệu.
SHR đo lường mức độ mà việc lặp lại quá trình chú thích dẫn đến các thứ hạng tương đối tương tự của các mẫu.

Đầu tiên, nó chia các chú thích bộ bốn (4-tuple annotations) thành hai nhóm (bins). Sau đó, các chú thích của mỗi nhóm được sử dụng để tạo ra hai bộ điểm số liên quan (relatedness scores) độc lập khác nhau, và hệ số tương quan Spearman giữa hai bộ điểm số này được tính toán để ước lượng mức độ gần nhau của hai thứ hạng. Một hệ số tương quan cao cho thấy các chú thích đáng tin cậy.

Quy trình này được lặp lại 1.000 lần và các điểm số tương quan được lấy trung bình, tương tự như cách của Abdalla và cộng sự (2023).

Nhìn chung, các điểm số trong Bảng 3 dao động từ 0.64 đến 0.96, điều này cho thấy độ tin cậy của việc chú thích rất cao.

Ngôn ngữ	Nam Phi	Amharic	Ả Rập Chuẩn	Ả Rập Algeria	Ả Rập Ma-rốc	Tiếng Anh	Tiếng TBN	Hausa	Hindi	Indonesia	Kinyarwanda	Marathi	Telugu
Tập huấn	-	992	-	1261	924	5500	1562	1736	-	-	778	1200	1170
Kiểm tra	375	171	595	583	426	2600	600	603	968	360	2222	298	297
Xác thực	375	95	32	97	71	250	140	212	288	144	102	293	130
Tổng cộng	700	1258	627	1941	1421	8350	2302	2551	1256	504	1102	1791	1597

Bảng 4: Số lượng mẫu (instances) trong tập huấn luyện (training), tập xác thực (dev), và tập kiểm tra (test) đối với các bộ dữ liệu khác nhau.

Các ngôn ngữ không có dữ liệu huấn luyện (Nam Phi, Ả Rập Chuẩn, Hindi, Indonesia) chỉ được sử dụng trong các thiết lập không giám sát (unsupervised) và thiết lập đa ngôn ngữ chéo (cross-lingual).

Những bất đồng Chúng tôi đã kiểm tra các annotator có mức độ bất đồng lớn để đảm bảo rằng quy trình chú thích được thực hiện đúng (tức là các chú thích của họ có ý nghĩa đối với người bản xứ). Những bất đồng rất mạnh sẽ là dấu hiệu cảnh báo về chất lượng dữ liệu kém, dẫn đến việc xem xét kỹ lưỡng hơn về chất lượng chú thích. Do đó, như một bước kiểm tra tính hợp lý (sanity check), chúng tôi đã xem xét liệu các cặp câu có điểm số liên quan cao có thực sự liên quan ngữ nghĩa hơn so với các cặp có điểm số liên quan thấp hay không.

Quy trình cụ thể để đảm bảo chất lượng dữ liệu phụ thuộc vào quy trình chú thích của từng nhóm (ví dụ: những nhóm sử dụng AMT so với những nhóm không sử dụng). Lưu ý rằng các bất đồng không bị xóa bỏ, vì chúng có thể đóng vai trò là tín hiệu hữu ích cho phương pháp BWS (Best-Worst Scaling). Cụ thể, đối với một bộ bốn ⟨p0, p1, p2, p3⟩, khi các annotator bất đồng về việc cái nào liên quan nhất (ví dụ: p1 hay p3), thì điều đó cho thấy p1 và p3 có thể liên quan ngữ nghĩa gần với nhau. Vì tất cả các chú thích của bộ bốn (gấp đôi số lượng mẫu) đều được sử dụng để xác định điểm số cuối cùng của các cặp câu, nên sự bất đồng này sẽ dẫn đến hai cặp (p1 và p3) nhận được điểm số gần nhau.

Mặt khác, nếu một cặp câu liên tục xuất hiện trong các bộ bốn có mức độ đồng thuận của annotator rất thấp, thì rất có khả năng chính cặp câu đó là nguồn gốc của sự bất đồng. Điều này có thể xuất phát từ nhiều lý do khác nhau, chẳng hạn như cách sử dụng ngôn ngữ, hiện tượng chuyển mã (code-switching), hoặc mức độ quen thuộc của annotator với chủ đề được thảo luận.

Bên cạnh việc chia sẻ bộ dữ liệu với cộng đồng, chúng tôi cũng công khai toàn bộ các chú thích bộ bốn (full 4-tuple annotations).

3.3 Hậu xử lý và kiểm soát chất lượng dữ liệu

Kiểm soát chất lượng Đối với bộ dữ liệu cuối cùng của chúng tôi, chúng tôi đã thực hiện một bước hậu xử lý dữ liệu để đảm bảo rằng:

- Không có mẫu nào bị lặp lại;

- Dữ liệu không chứa các ký tự vô hình, biểu tượng cảm xúc được hiển thị sai, hoặc các ký tự mã hóa bị hỏng;
- Văn bản được ẩn danh hoàn toàn (xóa email và ID nếu có, thay thế @mentions bằng @<username>, và thay thế bất kỳ URL nào bằng các placeholder không thể nhận dạng);
- Dữ liệu không chứa lượng lớn từ ngữ tục tĩu hoặc ngôn ngữ không phù hợp; và
- Dữ liệu được cân bằng (balanced).

Kiểm tra thủ công ngẫu nhiên (Manual Spotchecks) Cuối cùng, một nhóm người bản xứ đã thực hiện kiểm tra thủ công ngẫu nhiên (spot-check) các điểm số để đảm bảo rằng các điểm số liên quan (relatedness scores) có ý nghĩa hợp lý và để bổ sung cho việc đánh giá định lượng dựa trên SHR.

Ghi chú ngắn gọn về thuật ngữ:

- SHR: Có thể là viết tắt của "Semantic Human Relatedness" hoặc một chỉ số tương quan cụ thể được đề cập trước đó trong bài báo (thường là Spearman Human Correlation hoặc tương tự, dùng để đánh giá độ tin cậy của điểm số chú thích so với nhận thức con người).
- Đoạn này nằm trong phần mô tả quy trình hậu xử lý và đảm bảo chất lượng cuối cùng của bộ dữ liệu Semantic Textual Relatedness (STR) cho các ngôn ngữ ít tài nguyên.

4. Thí Nghiệm

4.1 Dữ liệu

Chúng tôi sử dụng các phân chia được báo cáo trong Bảng 4. Đối với các ngôn ngữ không có dữ liệu huấn luyện (afr, arb, hin, ind), chúng tôi chỉ báo cáo các thí nghiệm trong thiết lập không giám sát và đa ngôn ngữ. Đối với tiếng Anh, chúng tôi sử dụng tập dữ liệu STR2022 (Abdalla et al., 2023) để huấn luyện và sử dụng tập dữ liệu mới được tạo của chúng tôi để kiểm tra.

4.2 Thiết lập thí nghiệm

Chúng tôi báo cáo điểm số tương quan Spearman giữa các nhãn dự đoán và nhãn chuẩn vàng cho các ngôn ngữ khác nhau trong ba thiết lập chính:

- **Hệ thống có giám sát** được huấn luyện trên các tập dữ liệu huấn luyện được gắn nhãn.
- **Hệ thống không giám sát** được phát triển mà không sử dụng các tập dữ liệu được gắn nhãn liên quan đến mối quan hệ ngữ nghĩa hoặc sự tương đồng ngữ nghĩa giữa các đơn vị văn bản dài hơn hai từ trong bất kỳ ngôn ngữ nào.
- **Hệ thống đa ngôn ngữ** được phát triển mà không sử dụng bất kỳ tập dữ liệu tương đồng ngữ nghĩa hoặc mối quan hệ ngữ nghĩa nào được gắn nhãn trong ngôn ngữ đích và sử dụng dữ liệu từ ít nhất một ngôn ngữ khác được bao gồm trong SemRel.

Trong các thí nghiệm của chúng tôi, chúng tôi sử dụng:

- Một đường cơ sở đơn giản dựa trên số lượng từ được chia sẻ (sự trùng lặp từ vựng)

	afr	amh	arb	arq	ary	eng	esp	hau	hin	ind	kin	mar	tel
Sự chồng chéo	0.71	0.63	0.32	0.40	0.63	0.67	0.67	0.31	0.53	0.55	0.33	0.62	0.70
	Không giám sát (Đa ngôn ngữ)												
mBERT	0,74	0,13	0,42	0,37	0,27	0,68	0,66	0,16	0,62	0,50	0,12	0,65	0,66
XLMR	0,56	0,57	0,32	0,25	0,17	0,60	0,69	0,04	0,51	0,47	0,13	0,60	0,58
	Không giám sát (Đơn ngữ)												
AfroXLMR	0,45	0,40	0,18	-	-	0,30	-	0,07	-	-	0,16	-	-
ALBERTO	-	-	-	-	-	-	0,62	-	-	-	-	-	-
AmRoBERTa	-	0,72	-	-	-	-	-	-	-	-	-	-	-
ARBERT	-	-	0,56	-	-	-	-	-	-	-	-	-	-
arb BERT	-	-	0,31	-	-	-	-	-	-	-	-	-	-
BETO	-	-	-	-	-	-	0,68	-	-	-	-	-	-
DziriBERT	-	-	-	0,43	-	-	-	-	-	-	-	-	-
Indic-BERT	-	-	-	-	-	-	-	-	0,40	-	-	0,41	-
MARBERT	-	-	0,29	-	-	-	-	-	-	-	-	-	-
RoBERTa-BNE		-	-	-	-	-	0,66	-	-	-	-	-	-
HauRoBERTa	-	-	-	-	-	-	-	0,12	-	-	-	-	-
	Được giám sát												
LaBSE	-	0,85	-	0,60	0,77	0,83	0,70	069	-	-	0,72	0,88	0,82
	Đa ngôn ngữ												
LaBSE	0,79	0,84	0,61	0,46	0,40	0,80	0,62	0,62	0,76	0,47	0,57	0,84	0,82

Bảng 5: Điểm tương quan Spearman cho các mô hình được tinh chỉnh khác nhau trong ba thiết lập mà chúng tôi mô tả (có giám sát, không giám sát và đa ngôn ngữ) ngoài cơ sở trùng lặp từ vựng đơn giản (Overlap).

- Nhúng câu (LaBSE (Feng et al., 2020), SentenceBERT (Reimers and Gurevych, 2019)), và
- Các phép nhúng dựa trên bộ mã hóa tiêu chuẩn.

4.3 Sự trùng lặp từ vựng

Như thể hiện trong Bảng 5, chúng tôi báo cáo một từ vựng đơn giản đường cơ sở chồng chéo bao gồm hệ số Dice giữa hai câu A và B: số lượng gồm các từ đơn độc nhất xuất hiện trong cả hai câu, được điều chỉnh theo chiều dài của chúng (Abdalla et al., 2023):

$$\frac{2 \times |unigram(A) \cap unigram(B)|}{|unigram(A) + unigram(B)|}$$

4.4 Thiết lập học có giám sát và liên ngôn ngữ

Chúng tôi sử dụng LaBSE (Label-Agnostic BERT Sentence Embeddings) (Feng et al., 2020),một mô hình có khả năng ánh xạ 109 ngôn ngữ vào một không gian vector dùng chung.Do các embedding này bao phủ toàn bộ các ngôn ngữ trong SemRel, chúng tôi báo cáo các kết quả baseline bằng cách sử dụng bộ siêu tham số mặc định được thiết lập trong kho mã nguồn sentence-transformers[4].Các thí nghiệm của chúng tôi được tiến hành theo hai thiết lập:

- Sử dụng cấu hình được định nghĩa sẵn, không thực hiện fine-tuning bổ sung
- Bằng cách tinh chỉnh mô hình LaBSE trên dữ liệu huấn luyện của chúng tôi, sử dụng hàm mất mát cosine similarity.

[4] https://github.com/UKPLab/used-transformers

Chúng tôi báo cáo các điểm số trên tập kiểm thử trong cả hai thiết lập ở Phụ lục A, Bảng 12.

Đối với các baseline liên ngôn ngữ, chúng tôi tinh chỉnh LaBSE trên tập huấn luyện tiếng Anh và đánh giá trên tất cả các bộ dữ liệu còn lại, ngoại trừ tiếng Anh. Ngược lại, khi đánh giá trên bộ dữ liệu tiếng Anh, chúng tôi sử dụng tập huấn luyện tiếng Tây Ban Nha để nhằm mục đích tinh chỉnh LaBSE.

4.5 Thiết lập không giám sát

Chúng tôi sử dụng các mô hình ngôn ngữ đơn ngữ và đa ngôn ngữ tiêu chuẩn dựa trên encoder trên các bộ dữ liệu của mình[5]. Chúng tôi tiến hành thí nghiệm với:

- BERT đa ngôn ngữ (mBERT) (Devlin et al., 2019) và XLM-RoBERTa (XLM-R) (Conneau et al., 2020) cho tất cả 13 ngôn ngữ,
- các mô hình đơn ngữ, bao gồm:
  – AfroXLM-R (Alabi et al., 2022) cho tiếng Afrikaans, tiếng Amharic, tiếng Hausa và tiếng Kinyarwanda;
  – Indic-BERT (Kakwani et al., 2020) cho tiếng Hindi, tiếng Marathi và tiếng Telugu;
  – BERT (Devlin et al., 2019) cho tiếng Anh;
  – MARBERT, ARBERT (Abdul-Mageed et al., 2021) và ArabicBERT (Safaya et al., 2020) cho tiếng Ả Rập;
  – BETO (Cañete et al., 2020), ALBETO (Cañete et al., 2022) và RoBERTa cho tiếng Tây Ban Nha.

[5] Chúng tôi sử dụng các mô hình tiêu chuẩn từ Hugging Face (Wolf et al., 2020).

Nhóm 5:

BNE (Fandiño et al., 2022) cho tiếng Tây Ban Nha, Amharic RoBERTa (AmRoBERTa) (Yimam et al., 2021) cho tiếng Amharic, DziriBERT (Abdaoui et al., 2021) cho tiếng Ả Rập Algeria, và mô hình dựa trên RoBERTa (HauRoBERTa) cho tiếng Hausa (Adelani et al., 2022).

Chúng tôi báo cáo các điểm tương quan Spearman giữa điểm tương đồng cosine và nhãn vàng cho tất cả các mô hình dựa trên BERT trong Bảng 5. Các kết quả bổ sung sử dụng BERTScore (Zhang* et al., 2020) cho mBERT và XLM-R được trình bày trong Phụ lục (xem Bảng 13).

4.6 Kết quả thực nghiệm

Bảng 5 trình bày các điểm tương quan Spearman cho ba thiết lập: có giám sát, không giám sát và xuyên ngôn ngữ cho tất cả mười ba ngôn ngữ.

Đối với các mô hình không giám sát, chúng tôi báo cáo kết quả sử dụng tất cả các mô hình đã được huấn luyện sẵn, bao gồm mBERT (Devlin et al., 2019) và XLM-R (Conneau et al., 2020). Ngoài ra, chúng tôi cũng báo cáo hệ số tương quan Spearman cho các thí nghiệm sử dụng các mô hình đơn ngữ chuyên biệt cho từng ngôn ngữ — tức là các mô hình được huấn luyện riêng cho những ngôn ngữ đó.

Trong thiết lập tổng quát, chúng tôi nhận thấy rằng, ngoại trừ tiếng Amharic và Kinyarwanda, mBERT vượt trội hơn XLM-R ở tất cả các ngôn ngữ với một khoảng cách đáng kể.

Đối với tiếng Amharic, điểm tương quan của mBERT với nhãn vàng chỉ là 0.13, trong khi XLM-R đạt điểm cao gấp ba lần với hệ số tương quan 0.57.
Đáng ngạc nhiên là mặc dù tiếng Ả Rập là một ngôn ngữ giàu tài nguyên, điểm tương quan Spearman của nó lại tương đối thấp so với các ngôn ngữ giàu tài nguyên khác, trong đó tiếng Tây Ban Nha đạt kết quả tốt nhất. Điều này có thể do kích thước dữ liệu tiếng Ả Rập nhỏ hơn.

Đối với các mô hình chuyên biệt theo ngôn ngữ, kết quả phụ thuộc rất nhiều vào từng ngôn ngữ cụ thể. Ví dụ, với tiếng Amharic, AmRoBERTa cải thiện đáng kể điểm số lên 0.27, trong khi AfroXLM-R lại làm giảm hiệu năng đối với tất cả các ngôn ngữ châu Phi.

Tương tự như thiết lập không giám sát, các ngôn ngữ giàu tài nguyên đạt điểm cao nhất trong các thiết lập có giám sát và xuyên ngôn ngữ. Nhìn chung, chúng tôi ghi nhận các hệ số tương quan tương đối cao, dao động trong khoảng từ 0.40 đến 0.88.

5 Kết luận

Chúng tôi giới thiệu SemRel, một bộ sưu tập mới các tập dữ liệu đo lường mức độ liên quan ngữ nghĩa giữa các cặp câu (semantic textual relatedness) cho 13 ngôn ngữ, trong đó phần lớn là các ngôn ngữ được sử dụng chủ yếu ở châu Phi và châu Á và được xem là ngôn ngữ ít tài nguyên. Các cặp câu trong bộ dữ liệu được gán nhãn bởi người bản ngữ và đi kèm với các điểm số liên quan ngữ nghĩa chi tiết. Chúng tôi đã trình bày chi tiết quy trình tuyển chọn dữ liệu và nhấn mạnh những thách thức gặp phải khi làm việc với các ngôn ngữ ít tài nguyên. Chúng tôi công bố công khai các tập dữ liệu này cùng với các tài nguyên bổ sung như hướng dẫn gán nhãn và toàn bộ nhãn, nhằm phục vụ cộng đồng nghiên cứu quan tâm đến bài toán liên quan ngữ nghĩa, ngôn ngữ ít tài nguyên và các bất đồng trong gán nhãn.

6 Hạn chế

Chúng tôi thừa nhận rằng hiện không có một định nghĩa chính thức nào về "liên quan ngữ nghĩa". Do đó, các nhãn gán có thể mang tính chủ quan. Để giảm thiểu vấn đề này, chúng tôi chia sẻ các hướng dẫn gán nhãn và các mẫu dữ liệu đã được chú thích để các nhà nghiên cứu trong cộng đồng có thể mở rộng, tái lập và nghiên cứu các bất đồng trong dữ liệu của chúng tôi.

Chúng tôi cũng nhận thức được rằng số lượng nguồn dữ liệu và mức độ đa dạng dữ liệu ở một số ngôn ngữ ít tài nguyên còn hạn chế. Chúng tôi không khẳng định rằng các tập dữ liệu được công bố đại diện cho toàn bộ các biến thể của những ngôn ngữ này, nhưng chúng vẫn là một điểm khởi đầu tốt vì đã được lựa chọn, gán nhãn và xử lý cẩn thận bởi người bản ngữ.
Mặc dù bộ sưu tập của chúng tôi bao gồm nhiều tập dữ liệu, quy mô dữ liệu vẫn còn hạn chế, do đó không thể là nguồn dữ liệu duy nhất cho các tác vụ đòi hỏi lượng dữ liệu lớn, chẳng hạn như nhận dạng ngôn ngữ.

7 Các vấn đề đạo đức

Tất cả những người tham gia gán nhãn trong nghiên cứu này đều là tình nguyện viên hoặc được trả công cao hơn mức lương tối thiểu theo giờ, và mọi thông tin nhân khẩu học được báo cáo trong Phụ lục đều được chia sẻ với sự đồng ý của họ. Dữ liệu được gán nhãn bổ sung đều là dữ liệu công khai và đã được trích dẫn trong bài báo.

Tương tự như Abdalla et al. (2023), chúng tôi thừa nhận rằng dữ liệu của mình có thể mang theo các thiên lệch xã hội – văn hoá do nguồn dữ liệu hoặc quá trình gán nhãn. Khi xây dựng các tập dữ liệu, chúng tôi đã tránh các mẫu có nội dung không phù hợp hoặc xúc phạm, tuy nhiên có thể vẫn còn một số trường hợp bị bỏ sót. Mục tiêu của chúng tôi là xác định nhận thức chung của người bản ngữ về mức độ liên quan ngữ nghĩa, và các nhãn của chúng tôi không nhằm mục đích tiêu chuẩn hoá cho bất kỳ ngôn ngữ cụ thể nào. Lưu ý rằng mặc dù chúng tôi xây dựng các tập dữ liệu cho các ngôn ngữ ít tài nguyên, chúng tôi không khẳng định rằng các tập dữ liệu này hoàn toàn đại diện cho cách sử dụng của các ngôn ngữ đó.

Lời cảm ơn

Chúng tôi xin cảm ơn những người chú thích dữ liệu đã gắn nhãn cho dữ liệu và Cảm ơn những nhận xét sâu sắc cũng như Zara Siddique đã cung cấp thêm những thông tin hữu ích. Cảm ơn Dimosthenis Antypas, Joanne Bois- son, Hsuvas Borkakoty vì những phản hồi hữu ích.

Tài liệu tham khảo

Miguel Á. García Cumbreras, L. Alfonso Ureña López, và Fernando Martínez Santiago. 2006. PHÙ THỦY: Phân loại câu hỏi cho tiếng Tây Ban Nha. Sử dụng máy học bản dịch và một bộ phân loại tiếng Anh. Trong Kỷ yếu của Hội thảo về Hỏi đáp đa ngôn ngữ- MLQA '06.

Mohamed Abdalla, Krishnapriya Vishnubhotla và Saif Mohammad. 2023. Điều gì làm cho các câu có mối liên hệ ngữ nghĩa? Một bộ dữ liệu về mối liên hệ văn bản và nghiên cứu thực nghiệm. Trong Kỷ yếu Hội nghị lần thứ 17 của Chi hội Châu Âu thuộc Hiệp hội Ngôn ngữ học Tính toán, trang 782–796, Dubrovnik, Croatia. Hiệp hội Ngôn ngữ học Tính toán.

Amine Abdaoui, Mohamed Berrimi, Mourad Oussalah, và Abdelouahab Moussaoui. 2021. Dziribert: A Mô hình ngôn ngữ được huấn luyện trước cho phương ngữ Algeria. bản in trước arXiv arXiv:2109.12346.

Muhammad Abdul-Mageed, AbdelRahim Elmadany, và El Moatez Billah Nagoudi. 2021. ARBERT & MARBERT: Máy biến áp hai chiều sâu cho tiếng Ả Rập. Trong Kỷ yếu Hội nghị thường niên lần thứ 59 của Hiệp hội Ngôn ngữ học Tính toán và Hội nghị chung quốc tế lần thứ 11 về xử lý ngôn ngữ tự nhiên (Tập 1: Các bài báo dài), trang 7088–7105, Trực tuyến. Hiệp hội Tính toán Ngôn ngữ học.

Idris Abdulmumin và Bashir Shehu Galadanci. 2019. hauwe: Nhúng từ tiếng Hausa cho ngôn ngữ tự nhiên xử lý. Tại Hội nghị Quốc tế lần thứ 2 năm 2019 Chi hội Máy tính IEEE Nigeria (NigeriaCom- putConf). IEEE.

Karima Abidi, Mohamed Amine Menacer và Kamel Smaili. 2017. CALYOU: Một kho ngữ liệu tiếng Algeria nói tương đương được thu thập từ YouTube. Trong Hội nghị thường niên lần thứ 18. Hội nghị của Hiệp hội Truyền thông Quốc tế (Interspeech).

David Adelani, Graham Neubig, Sebastian Ruder, Shruti Rijhwani, Michael Beukman, Chester Palen- Michel, Constantine Lignos, Jesujoba Alabi, Sham -suddeen Muhammad, Peter Nabende, Cheikh M. Bamba Dione, Sách Andiswa, Roow Hoặc Mabuya, Bonaventure FP Dossou, Phước lành cho Sibanda, Chúc mừng Buzaaba, Jonathan Mukiibi, Godson Kape, Derguene Mbaye, Amelia Taylor, Fatoumata Kabore , Chris Chinenye Emezue, Anuoluwapo Aremu Perez Ogayo, Catherine Gitau, Edwin Munkoh-Buabeng, Victoire Memdjokam Koagne, Allah -sera Auguste Tapo, Tebogo Macucwa, Vukosi Marivate , Mboning Tchiaze Elvis, Tajuddeen Gwad-abe, Tosin Adewumi, Orevaoghene Joyce Ahia Nakatumba-Nabende, Neo Lerato Mokono, Ignatius Ezeani, Chiamaka Chukwuneke, Mofetoluwa Oluwaseun Adeyemi, Gilles Quentin Hacheme, Idris Abdulmumin, Odunayo Ogundepo, Oreen Yousuf, Tatiana Moteu và Dietrich Klakow. 2022. MasakhaNER 2.0: Học tập chuyển giao tập trung vào châu Phi để nhận dạng thực thể được đặt tên. Trong Biên bản của Hội nghị năm 2022 về các phương pháp thực nghiệm trong xử lý ngôn ngữ tự nhiên, trang 4488–4508, Abu Dhabi, Các Tiểu vương quốc Ả Rập Thống nhất. Hiệp hội Ngôn ngữ học Máy tính.

Eneko Agirre, Carmen Banea, Claire Cardie, Daniel Cer, Mona Diab, Aitor Gonzalez-Agirre, Weiwei Guo, Inigo Lopez-Gazpio, Montse Maritxalar, Rada Mihalcea , và những người khác. 2015. SemEval-2015 nhiệm vụ 2: Ngữ nghĩa Sự tương đồng về văn bản, tiếng Anh, tiếng Tây Ban Nha và thí điểm về khả năng diễn giải. Trong Kỷ yếu của Hội nghị quốc tế lần thứ 9 Hội thảo về đánh giá ngữ nghĩa (SemEval 2015), trang 252–263, Denver, Colorado. Hiệp hội Ngôn ngữ học tính toán.

Eneko Agirre, Carmen Banea, Claire Cardie, Daniel Cer, Mona Diab, Aitor Gonzalez-Agirre, Weiwei Guo, Rada Mihalcea, Rigau người Đức và Janyce Wiebe. 2014. SemEval-2014 nhiệm vụ 10: Ngữ nghĩa đa ngôn ngữ sự tương đồng về văn bản. Trong Kỷ yếu Hội thảo quốc tế lần thứ 8 về đánh giá ngữ nghĩa (SemEval) (2014), trang 81–91, Dublin, Ireland. Hiệp hội Ngôn ngữ học tính toán.

Eneko Agirre, Carmen Banea, Daniel Cer, Mona Diab, Aitor Gonzalez Agirre, Rada Mihalcea, người Đức Rigau Claramunt và Janyce Wiebe. 2016. SemEval- 2016 Nhiệm vụ 1: Độ tương đồng ngữ nghĩa văn bản, đánh giá đơn ngữ và đa ngữ. Trong SemEval-2016. Hội thảo quốc tế lần thứ 10 về đánh giá ngữ nghĩa; ngày 16-17 tháng 6 năm 2016; San Diego, CA. Stroudsburg (PA): ACL; 2016. tr. 497-511. ACL (Hiệp hội) Ngôn ngữ học tính toán).

Eneko Agirre, Daniel Cer, Mona Diab và Aitor Gonzalez-Agirre. 2012. SemEval-2012 Nhiệm vụ 6: A Thí điểm về độ tương đồng ngữ nghĩa văn bản. Trong *SEM 2012: Hội nghị chung đầu tiên về ngữ nghĩa từ vựng và tính toán – Tập 1: Kỷ yếu của Hội nghị. Hội nghị chính và nhiệm vụ chung, và khối lượng 2: Biên bản Hội thảo Quốc tế lần thứ sáu trong Hội nghị Đánh giá Ngữ nghĩa (SemEval 2012), trang 385-393.

Eneko Agirre, Daniel Cer, Mona Diab, Aitor Gonzalez- Agirre và Weiwei Guo. 2013a. *SEM 2013 được chia sẻ Nhiệm vụ: So sánh độ tương đồng ngữ nghĩa của văn bản. Trong khớp thứ hai Hội nghị về ngữ nghĩa từ vựng và tính toán (*SEM), Tập 1: Kỷ yếu Hội nghị Chính và Nhiệm vụ Chung: Độ tương đồng ngữ nghĩa văn bản , trang 32–43, Atlanta, Georgia, Hoa Kỳ. Hiệp hội cho Ngôn ngữ học tính toán.

Mahtab Ahmed, Chahna Dixit, Robert E. Mercer, Atif Khan, Muhammad Rifayat Samee và Felipe Urra (2020).
Xây dựng kho ngữ liệu đa ngôn ngữ phục vụ bài toán đo độ tương đồng ngữ nghĩa đa ngôn ngữ. Công bố trong Kỷ yếu Hội nghị Tài nguyên và Đánh giá Ngôn ngữ lần thứ mười hai, trang 4190–4196.

Ahmed Hashim Al-Dulaimi (2022).
Tập dữ liệu tin tức tiếng Ả Rập phục vụ nghiên cứu xử lý ngôn ngữ tự nhiên.

Jesujoba O. Alabi, David Ifeoluwa Adelani, Marius Mosbach và Dietrich Klakow (2022).
Thích nghi các mô hình ngôn ngữ đã được huấn luyện sẵn cho các ngôn ngữ châu Phi thông qua kỹ thuật tinh chỉnh đa ngôn ngữ. Công bố tại Hội nghị Ngôn ngữ học Tính toán Quốc tế lần thứ 29.

Vladimir Araujo, Andrés Carvallo, Souvik Kundu, José Cañete, Marcelo Mendoza, Robert E. Mercer, Felipe Bravo-Marquez, Marie-Francine Moens và Alvaro Soto (2022).
Các bộ chuẩn đánh giá cho biểu diễn câu trong tiếng Tây Ban Nha. Công bố tại Hội nghị Tài nguyên và Đánh giá Ngôn ngữ lần thứ mười ba.

Carlos Santos Armendariz, Matthew Purver, Senja Pollak, Nikola Ljubešić, Matej Ulčar, Ivan Vulić và Mohammad Taher Pilehvar (2020).
Nhiệm vụ SemEval-2020: Đánh giá mức độ tương đồng của từ trong ngữ cảnh.

Samuel R. Bowman, Gabor Angeli, Christopher Potts và Christopher D. Manning (2015).
Một kho ngữ liệu quy mô lớn có gán nhãn phục vụ việc học suy luận ngôn ngữ tự nhiên.

José Cañete, Sebastian Donoso, Felipe Bravo-Marquez, Andrés Carvallo và Vladimir Araujo (2022).
ALBETO và DistilBETO: Các mô hình ngôn ngữ tiếng Tây Ban Nha gọn nhẹ nhưng hiệu quả.

José Cañete, Gabriel Chaperon, Rodrigo Fuentes, Jou-Hui Ho, Hojin Kang và Jorge Pérez (2020).
Mô hình BERT được huấn luyện sẵn cho tiếng Tây Ban Nha cùng với các bộ dữ liệu đánh giá.

Daniel Cer, Mona Diab, Eneko Agirre, Iñigo Lopez-Gazpio và Lucia Specia (2017).
Nhiệm vụ SemEval-2017: Đánh giá độ tương đồng văn bản ngữ nghĩa trong môi trường đa ngôn ngữ và liên ngữ.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer và Veselin Stoyanov (2020).
Học biểu diễn liên ngữ không giám sát ở quy mô lớn.

Lee J. Cronbach (1951).
Hệ số alpha và cấu trúc bên trong của các bài kiểm tra, nền tảng cho việc đánh giá độ tin cậy.

Jacob Devlin, Ming-Wei Chang, Kenton Lee và Kristina Toutanova (2019).
BERT: Phương pháp huấn luyện trước các mô hình transformer hai chiều sâu cho bài toán hiểu ngôn ngữ tự nhiên.

Asier Gutiérrez-Fandiño, Jordi Armengol-Estapé, Marc Pàmies, Joan Llop Palao, Joaquin Silveira Ocampo, Casimiro Pio Carrino, Carme Armentano Oller, Carlos Rodriguez Penagos, Aitor Gonzalez-Agirre và Marta Villegas (2022).
MARIA: Hệ thống các mô hình ngôn ngữ dành cho tiếng Tây Ban Nha.

Fangxiaoyu Feng, Yinfei Yang, Daniel Cer, Naveen Arivazhagan và Wei Wang (2020).
Biểu diễn câu bằng BERT theo hướng không phụ thuộc vào ngôn ngữ.

Charles A. Ferguson (1959).
Hiện tượng song ngữ chức năng trong ngôn ngữ học xã hội.

Terry N. Flynn và Anthony A. J. Marley (2014).
Phương pháp Best–Worst Scaling: Cơ sở lý thuyết và phương pháp thực hiện.

Goran Glavaš, Marc Franco-Salvador, Simone Paolo Ponzetto và Paolo Rosso (2018).
Phương pháp ít tài nguyên cho bài toán đo độ tương đồng văn bản ngữ nghĩa liên ngữ.

Ruqaiya Hasan và Michael A. K. Halliday (1976).
Tính liên kết trong tiếng Anh và vai trò của nó trong cấu trúc văn bản.

Tahmid Hasan, Abhik Bhattacharjee, Md Saiful Islam và cộng sự (2021).
XL-Sum: Tập dữ liệu tóm tắt trừu tượng đa ngôn ngữ quy mô lớn cho 44 ngôn ngữ.

Javier Huertas-Tato, Alejandro Martín và David Camacho (2021).
SILT: Phương pháp huấn luyện transformer hiệu quả cho suy luận liên ngữ.

Abderrahmane Issam và Khalil Mrini (2022).
Goud.ma: Tập dữ liệu bài báo tin tức phục vụ bài toán tóm tắt văn bản tiếng Darija của Morocco.

Divyanshu Kakwani, Anoop Kunchukuttan, Satish Golla và cộng sự (2020).
IndicNLPSuite: Kho ngữ liệu, bộ đánh giá và các mô hình ngôn ngữ cho các ngôn ngữ Ấn Độ.

Svetlana Kiritchenko và Saif M. Mohammad (2016).
Thu thập các liên kết cảm xúc chi tiết và đáng tin cậy bằng phương pháp crowdsourcing kết hợp Best–Worst Scaling.

Svetlana Kiritchenko và Saif M. Mohammad (2017).
Best–Worst Scaling cho độ tin cậy cao hơn so với thang điểm truyền thống trong gán nhãn cường độ cảm xúc.

G. Frederic Kuder và Marion W. Richardson (1937).
Lý thuyết ước lượng độ tin cậy của các bài kiểm tra.

Kemal Kurniawan và Samuel Louvan (2018).
IndoSum: Tập dữ liệu chuẩn cho bài toán tóm tắt văn bản tiếng Indonesia.

Hugo Laurençon, Lucile Saulnier, Thomas Wang và cộng sự (2022).
BigScience ROOTS: Tập dữ liệu đa ngôn ngữ tổng hợp quy mô rất lớn (1,6 terabyte).

Jordan J. Louviere và George G. Woodworth (1991).
Best–Worst Scaling: Mô hình đánh giá sự khác biệt lớn nhất giữa các lựa chọn.

Lokesh Madasu, Gopichand Kanumolu, Nirmal Surange và Manish Shrivastava (2023).
Mukhyansh: Tập dữ liệu sinh tiêu đề cho các ngôn ngữ Ấn Độ.

George A. Miller (1994).
WordNet: Cơ sở dữ liệu từ vựng dành cho tiếng Anh.

George A. Miller và Walter G. Charles (1991).
Các yếu tố ngữ cảnh ảnh hưởng đến độ tương đồng ngữ nghĩa.

Saif Mohammad (2008).
Đo khoảng cách ngữ nghĩa bằng các hồ sơ phân bố khái niệm.

Saif Mohammad và Graeme Hirst (2012).
Tổng quan các thước đo phân bố dùng để xác định khoảng cách ngữ nghĩa.

Jane Morris và Graeme Hirst (1991).
Liên kết từ vựng như một chỉ báo phản ánh cấu trúc văn bản.

Rubungo Andre Niyongabo, Qu Hong, Julia Kreutzer và Li Huang (2020).
KINNEWS và KIRNEWS: Đánh giá phân loại văn bản liên ngữ cho tiếng Kinyarwanda và Kirundi.

Bryan K. Orme (2009).
Phân tích MaxDiff trong nghiên cứu lựa chọn.

Pedro Javier Ortiz Suárez, Laurent Romary và Benoît Sagot (2020).
Cách tiếp cận đơn ngữ cho embedding từ theo ngữ cảnh đối với các ngôn ngữ có mức tài nguyên trung bình.

Rajat Pandit, Saptarshi Sengupta, Sudip Kumar Naskar, Niladri Sekhar Dash và Mohini Mohan Sardar. 2019. Nâng cao sự tương đồng về ngữ nghĩa bằng cách sử dụng các nguồn tài nguyên đa ngôn ngữ: Một nghiên cứu về tiếng Bangla - một ngôn ngữ có nguồn tài nguyên hạn chế. Trong *Tin học*, tập 6, trang 19. MDPI.

Sudha Rao và Joel Tetreault. 2018. Kính thưa quý ông/bà, tôi xin được giới thiệu bộ dữ liệu GYAFC: Tập dữ liệu, tiêu chuẩn và số liệu cho việc chuyển đổi phong cách trang trọng. Trong *Kỷ yếu Hội nghị năm 2018 của Chương Bắc Mỹ thuộc Hiệp hội Ngôn ngữ học Tính toán: Công nghệ Ngôn ngữ Con người, Tập 1 (Bài báo dài)*, trang 129–140, New Orleans, Louisiana. Hiệp hội Ngôn ngữ học Tính toán.

Nils Reimers và Iryna Gurevych. 2019. BERT Câu: Nhúng câu sử dụng mạng BERT ghép đôi. Trong *Kỷ yếu Hội nghị năm 2019 về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên. Hiệp hội Ngôn ngữ học Tính toán.*

Ali Safaya, Moutasem Abdullatif và Deniz Yuret. 2020. KUISAIL tại SemEval-2020 nhiệm vụ 12: BERT- CNN để nhận diện ngôn ngữ xúc phạm trên mạng xã hội. Trong *Kỷ yếu Hội thảo lần thứ mười bốn về Đánh giá ngữ nghĩa*, trang 2054–2059, Barcelona (trực tuyến). Ủy ban Quốc tế về Tính toán Ngôn ngữ học.

Ali Safaya, Moutasem Abdullatif và Deniz Yuret. 2020. KUISAIL tại SemEval-2020 nhiệm vụ 12: BERT CNN để nhận diện lời nói xúc phạm trên mạng xã hội. Trong *Kỷ yếu Hội thảo lần thứ mười bốn về Đánh giá ngữ nghĩa*, trang 2054–2059, Barcelona (trực tuyến). Ủy ban Quốc tế về Ngôn ngữ học Tính toán.

Ken Nabila Setya và Rahmad Mahendra. 2018. Suy luận văn bản bán giám sát trên dữ liệu Wikipedia tiếng Indonesia. Trong *Hội nghị Quốc tế về Ngôn ngữ học Tính toán và Xử lý Văn bản Thông minh*, trang 416–427. Springer

Xin Tang, Shanbo Cheng, Loc Do, Zhiyu Min, Feng Ji, Heng Yu, Ji Zhang và Haiqin Chen. 2018. Cải thiện độ tương đồng ngữ nghĩa văn bản đa ngôn ngữ với bộ mã hóa câu chung cho các ngôn ngữ có nguồn tài nguyên thấp. *Bản thảo arXiv arXiv:1810.08740.*

Ivan Vuli´c, Simon Baker, Edoardo Maria Ponti, Ulla Petti, Ira Leviant, Kelly Wing, Olga Majewska, Eden Bar, Matt Malone, Thierry Poibeau, et al. 2020. Multi-simlex: Đánh giá quy mô lớn về độ tương đồng ngữ nghĩa từ vựng đa ngôn ngữ và xuyên ngôn ngữ. *Ngôn ngữ học tính toán*, 46(4):847–897.

Mengting Wan và Julian McAuley. 2018. Đề xuất mặt hàng trên chuỗi hành vi đơn điệu. Trong *Kỷ yếu Hội nghị ACM lần thứ 12 về hệ thống đề xuất*, trang 86–94.

Bin Wang, C.-C. Jay Kuo và Haizhou Li. 2022. Xếp hạng công bằng: Suy nghĩ lại về đánh giá với sự tương đồng giữa từ và câu. Trong *Kỷ yếu Hội nghị thường niên lần thứ 60 của Hiệp hội Ngôn ngữ học tính toán (Tập 1: Bài báo dài)*, trang 6060–6077, Dublin, Ireland. Hiệp hội Ngôn ngữ học tính toán.

Bin Wang và Haizhou Li. 2022. Nhúng câu quan hệ để khớp ngữ nghĩa linh hoạt. Bản thảo *arXiv arXiv:2212.08802.*

John Wieting và Kevin Gimpel. 2017. Paranmt-50m: Vượt qua giới hạn của việc nhúng câu diễn giải với hàng triệu bản dịch máy. *Bản thảo arXiv arXiv:1711.05732.*

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Remi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest và Alexander Rush. 2020. Transformers: Xử lý ngôn ngữ tự nhiên hiện đại nhất. Trong *Kỷ yếu Hội nghị năm 2020 về Phương pháp thực nghiệm trong xử lý ngôn ngữ tự nhiên: Trình diễn hệ thống*, trang 38–45, Trực tuyến. Hiệp hội Ngôn ngữ học Tính toán.

Yinfei Yang, Yuan Zhang, Chris Tar, và Jason Baldridge. 2019. PAWS-X: Một tập dữ liệu đối kháng đa ngôn ngữ để nhận dạng diễn đạt lại. Trong *Kỷ yếu Hội nghị về Phương pháp Thực nghiệm trong Xử lý Ngôn ngữ Tự nhiên năm 2019 và Hội nghị Quốc tế chung lần thứ 9 về Xử lý Ngôn ngữ Tự nhiên (EMNLP-IJCNLP)*, trang 3687–3692, Hồng Kông, Trung Quốc. Hiệp hội Ngôn ngữ học Tính toán.

Seid Muhie Yimam, Abinew Ali Ayele, Gopalakrishnan Venkatesh, Ibrahim Gashaw, và Chris Biemann. 2021. Giới thiệu các mô hình ngữ nghĩa khác nhau cho tiếng Amharic: Thử nghiệm và đánh giá với nhiều nhiệm vụ và tập dữ liệu. *Internet Tương lai*, 13(11).

Yunjin Yum, Jeong Moon Lee, Moon Joung Jang, Yoojoong Kim, Jong-Ho Kim, Seongtae Kim, Unsub Shin, Sanghoun Song và Hyung Joon Joo. 2021. Bộ dữ liệu cặp từ cho sự tương đồng ngữ nghĩa và mối liên hệ trong từ vựng y khoa tiếng Hàn: Phát triển và xác thực tài liệu tham khảo. *JMIR Medical Informatics*, 9(6):e29667.

Tianyi Zhang*, Varsha Kishore*, Felix Wu*, Kilian Q. Weinberger và Yoav Artzi. 2020. Bertscore: Đánh giá việc tạo văn bản bằng BERT. Trong *Hội nghị Quốc tế về Biểu diễn Học tập.*

Chengqing Zong. 2015. Cải thiện SMT bằng cách lọc mô hình và nhúng cụm từ. Trong *Kỷ yếu Hội thảo Quốc tế lần thứ 12 về Dịch thuật Ngôn ngữ Nói: Bài phát biểu chính*, Đà Nẵng, Việt Nam

Phụ lục A Chú thích

A.1 Chú thích dữ liệu thí điểm

Để đánh giá các kỹ thuật ghép cặp khác nhau và những thách thức tiềm tàng trong việc chú thích, chúng tôi đã thực hiện một nhiệm vụ chú thích thử nghiệm trên 20 đến 100 cặp câu cho mỗi ngôn ngữ trước khi tiến hành với các lô chú thích lớn hơn. Điều này giúp chúng tôi đánh giá những khó khăn liên quan đến nhiệm vụ chú thích và các lựa chọn cần đưa ra cho bước xử lý dữ liệu cuối cùng. Ví dụ, nếu các cặp câu có liên quan mật thiết và không liên quan mật

thiết xuất hiện quá thường xuyên trong các bộ dữ liệu, chúng tôi đã giảm tỷ lệ phần trăm của cả hai loại này bằng cách thay đổi hoặc hiệu chỉnh nguồn dữ liệu nếu có thể, ưu tiên các kỹ thuật ghép cặp khác hoặc bao gồm một bước tiền xử lý bổ sung (ví dụ: phát hiện diễn giải lại).

Ngôn ngữ	**Tập dữ liệu (%)**
afr - Tiếng Afrikaans (Nam Phi)	Oscar (100%).
amh - Tiếng Amharic	Dữ liệu tin tức (100%).
arb - Tiếng Ả Rập chuẩn	Phụ đề bài thuyết trình TED về khoa học, nghệ thuật và xã hội (96%), Dữ liệu tin tức kinh tế (4%).
arq - Tiếng Ả Rập Algeria	Dữ liệu hội thoại (89%), Bình luận trên Youtube (11%).
ary - Tiếng Ả Rập Maroc	Dữ liệu tin tức (100%).
eng - Tiếng Anh	Wikipedia (29%), ParaNMT (17%), Formality (17%), SNLI (8%), Goodreads (22%), STS (7%).
esp - Tiếng Tây Ban Nha	MuchoChine (MC) (7%), Spanish QC (4%), PAWS-X (19,5%), NLI-es (12%), SICK-es (17%), STS (5%), BSO (17,5%), XL-Sum (18%).
hau - Tiếng Hausa	Dữ liệu tin tức (100%).
hin - Tiếng Hindi	Dữ liệu tin tức (100%).
ind - Tiếng Indonesia	Dữ liệu tin tức (82%), Wikipedia/ROOTS (18%).
kin - Tiếng Kinyarwanda	Dữ liệu tin tức (100%).
mar - Tiếng Marathi	Dữ liệu tin tức (100%).
tel - Tiếng Telugu	Dữ liệu tin tức (100%).

Bảng 6: Tỷ lệ phần trăm các trường hợp được thu thập từ các nguồn khác nhau (tập dữ liệu).

A.2 Công cụ tiền xử lý dữ liệu

Chúng tôi đã sử dụng các công cụ NLTK để phân tích cú pháp tiếng Afrikaans và tiếng Indonesia, bên cạnh việc xác minh thủ công. Ví dụ, đối với tiếng Indonesia, quá trình phân tích câu của NLTK tạo ra nhiều lỗi do các từ viết tắt phổ biến trong tiếng Indonesia có chứa dấu chấm (.), mà trình phân tích câu nhận diện nhầm là dấu kết thúc câu. Vì vậy, chúng tôi đã

thêm các từ viết tắt mới để phân tích cú pháp ('ir.', 'kh.', 'h.', 'drs.', 'drg.', 'rm.', 'bp.', 'bpk.', 'tgl.', 'no.', 'jl.' và 'jln.').

A.3 Thông tin về người chú thích

Chúng tôi báo cáo về thông tin nhân khẩu học của các tình nguyện viên đã đồng ý chia sẻ thông tin.

Tiếng Afrikaans Người bản ngữ được trả lương.

Tiếng Amharic Người bản ngữ nói tiếng Amharic được trả lương, gồm 3 nữ và 5 nam đến từ các nền tảng xã hội, văn hóa và dân tộc khác nhau (Amhara, Guragie, Wolyta, Sidama và Oromo).

Tiếng Ả Rập chuẩn hiện đại và tiếng Ả Rập Algeria Người bản ngữ, gồm 2 nam, 2 nữ, có bằng đại học, độ tuổi từ 23 đến 56, được trả lương trên mức lương tối thiểu.

Tiếng Ả Rập Maroc tình nguyện viên bản ngữ, gồm 3 nữ, 1 nam, có bằng đại học, là tình nguyện viên.

Người làm việc trên Amazon Mechanical Turk bằng **tiếng Anh và tiếng Tây Ban Nha** với tỷ lệ chấp nhận cao (98% đối với tiếng Anh) được trả lương cao hơn mức lương tối thiểu của Mỹ.

Người bản ngữ nói **tiếng Hausa** được trả lương, 3 nữ, 1 nam, độ tuổi: 28 đến 30, có bằng cử nhân.

Người bản ngữ nói **tiếng Hindi và Marathi** được trả lương.

Người bản ngữ tình nguyện nói **tiếng Telugu**.

A.4 Hướng dẫn chú thích

Bạn sẽ được cung cấp bốn cặp câu (tức là 4 cặp có dạng [câu A, câu B]). Nhiệm vụ của bạn là đánh giá mức độ liên quan của mỗi cặp (câu A và câu B) và **cho chúng tôi biết**:

- Cặp câu nào có **mức độ liên quan CAO NHẤT** (tức là câu A có nghĩa gần nhất với câu B).
- Cặp câu nào có **mức độ liên quan ÍT NHẤT** (tức là câu A có nghĩa xa nhất với câu B).

Các cặp câu có thể liên quan với nhau theo nhiều cách. Ví dụ, câu A và câu B có thể liên quan với nhau theo những cách khác nhau. Cặp câu đầu tiên trong Bảng 7 có mức độ liên quan cao hơn cặp câu thứ hai. Thông thường, các cặp câu có nội dung cụ thể hơn thường có mức độ liên quan cao hơn các cặp câu chỉ đề cập đến cùng một chủ đề một cách lỏng lẻo.

Nếu một câu có nhiều hơn một cách hiểu, hãy xem xét cách hiểu nào gần nhất với cách hiểu của câu còn lại trong cặp đó. Nếu cả hai câu đều có nhiều nghĩa, thì hãy xem xét những nghĩa nào gần nhau nhất.

Nếu trong tập hợp bốn cặp câu đã cho, có hai (hoặc nhiều hơn) cặp câu có mối liên hệ ngang nhau với nhau

Cặp liên quan nhất S1: Cậu bé thích đọc sách dưới gốc cây chanh

S2: Có một cây chanh bên cạnh nhà.

Cặp ít liên quan nhất S1:

S2: Tôi có một chiếc mũ màu xanh lá cây.

S2: Cậu bé là một cầu thủ bóng đá xuất sắc.

Bảng 7: Ví dụ trong Hướng dẫn. Ví dụ về hai cặp câu có mức độ liên quan khác nhau .

Loại cặp	**Nội dung**
Cặp liên quan NHẤT	S1: Cậu bé thích ngồi đọc sách dưới gốc cây chanh. S2: Có một cây chanh ở ngay bên cạnh ngôi nhà.
Cặp KÉM liên quan NHẤT	S1: Cậu bé thích ngồi đọc sách dưới gốc cây chanh. S2: Cậu bé là một cầu thủ bóng đá xuất sắc.

Bảng 8: Ví dụ trong Hướng dẫn. Ví dụ về hai cặp câu có mức độ liên quan tương đương nhau, nơi bạn có thể chọn ngẫu nhiên cặp liên quan nhất so với cặp kém liên quan nhất (nghĩa là chọn Cặp 1 hoặc Cặp 2) .

Tên cặp	**Nội dung**
Cặp 1	**S1:** Cậu bé thích ngồi đọc sách dưới gốc cây chanh. **S2:** Tôi có một chiếc mũ màu xanh lá.

Cặp 2	**S1:** Cậu bé thích ngồi đọc sách dưới gốc cây chanh. **S2:** Cô ấy là một cầu thủ bóng đá xuất sắc.

Nếu trong bộ 4 cặp câu được đưa ra, có hai (hoặc nhiều) cặp câu có mức độ liên quan ngang nhau và chúng cũng là những cặp liên quan nhất, thì hãy chọn một trong số chúng làm cặp liên quan nhất (tức là chọn ngẫu nhiên).

Tương tự, nếu hai (hoặc nhiều) cặp có mức độ liên quan ngang nhau và cũng là những cặp kém liên quan nhất, hãy chọn một trong số chúng làm cặp kém liên quan nhất[4]. (Xem Bảng 2 / Bảng 8).

Bạn không thể chọn cùng một cặp câu cho cả hai hạng mục.

Đừng suy nghĩ quá nhiều về câu trả lời. Hãy để trực giác dẫn dắt bạn.

A.5 Lưu ý (Notes)

Các cặp câu có thể liên quan theo nhiều cách. Hãy xem xét toàn bộ ý nghĩa của các câu trước khi chọn cặp liên quan nhất. Các câu được đưa vào trong tác vụ này có thể chứa ngôn từ thô tục/xúc phạm, mặc dù chúng tôi đã cố gắng hạn chế điều này.

A.6 Ví dụ (Q1)

Cặp nào trong bốn cặp câu ở Bảng 9 là **LIÊN QUAN NHẤT**? Cặp nào là **KÉM LIÊN QUAN NHẤT**?

A.6.1 Trả lời (A1)

- **Cặp liên quan nhất là Cặp 3** vì cả hai câu đều nói về một nhóm người đang ngồi/nghỉ ngơi trên bãi cỏ.
- **Cặp kém liên quan nhất là Cặp 4** vì các câu trong Cặp 4 hoàn toàn không liên quan, trong khi các cặp khác có sự liên quan nhất định.

A.6.2 Ghi chú (A1)

- Các câu trong **Cặp 1** có phần liên quan, vì chúng nói về Narnia/các nhân vật trong thế giới đó (Aslan và Bree là các nhân vật trong Narnia)[12]. Tuy nhiên, nội dung của cặp câu này không liên quan chặt chẽ như Cặp 3.
- Các câu trong **Cặp 2** đều nói về các mối quan hệ tình cảm

A.7. Ví dụ (Câu hỏi 2)

Trong bốn cặp câu ở **Bảng 10**, cặp nào có mối liên hệ mật thiết nhất?
Cặp nào có mối liên hệ ít mật thiết nhất?

A.7.1. Đáp án A2

Cặp câu có mối liên hệ mật thiết nhất là **Cặp 4**, vì cả hai câu đều nói về cùng một thành phố và cùng đề cập đến việc thành phố đó nằm bên bờ sông **Sarayu**.

Cặp câu có mối liên hệ ít mật thiết nhất là **Cặp 2**, do nội dung của hai câu hoàn toàn không liên quan đến nhau.

A.7.2. Ghi chú (A2)

Các câu trong **Cặp 3** đều đề cập đến ít nhất một người phụ nữ, do đó có một mức độ liên hệ nhất định.

Các câu trong **Cặp 1** đề cập đến trẻ em hoặc các vấn đề liên quan đến trẻ em, khiến nội dung của chúng có sự tương đồng về chủ đề.

A.8. Ví dụ (Câu hỏi 3)

Trong bốn cặp câu ở **Bảng 11**, cặp nào có mối liên hệ mật thiết nhất?
Cặp nào có mối liên hệ ít mật thiết nhất?

A.8.1. Đáp án A3

Cặp câu có mối liên hệ mật thiết nhất là **Cặp 4**, vì hai câu này thực chất là các cách diễn đạt lại cùng một nội dung.
(Cặp 1 và Cặp 2 cũng có mức độ liên hệ tương đối, nhưng không phải là diễn đạt lại chính xác như Cặp 4.)

Cặp câu có mối liên hệ ít mật thiết nhất là **Cặp 3**. Mặc dù cả hai câu đều nói về đồ nội thất trong nhà, nhưng mức độ liên hệ giữa chúng vẫn thấp hơn so với các cặp còn lại.

bảng 9

Cặp	**Câu 1 (S1)**	**Câu 2 (S2)**
1	Những đoạn hội thoại giữa Aslan và Bree là những đoạn tôi thích nhất trong Narnia.	Phần này đánh dấu tiến trình đọc bộ truyện Biên niên sử Narnia của tôi.

2	Tại sao cô ấy không chịu rủ tôi đi chơi?	Sau tất cả những điều đó, bạn sẽ không còn phải lo lắng về việc làm sao để con gái thích mình nữa.
3	Một nhóm người đang ngồi trên bãi cỏ bên ngoài một tòa nhà mộc mạc.	Một nhóm người đang ngồi nghỉ ngơi trên một ngọn đồi cỏ.
4	Nếu các bạn biến tôi trở lại hình dạng ban đầu, tôi sẽ cho mỗi con rắn của các bạn ăn một con chuột lớn!	Tặng tiền mặt và phiếu giảm giá cho những người tham gia.

---

bảng 10

Cặp	Câu 1 (S1)	Câu 2 (S2)
1	Cái đó và một suất ăn cho trẻ em.	Hai đứa con của tôi, 5 và 3 tuổi.
2	Các gai, có thể dài tới 50 mm, là những sợi lông biến đổi.	Hình dạng đơn giản nhất là hình chữ nhật dài với vòm nhọn.
3	Một người phụ nữ mặc áo sơ mi trắng và băng đô đỏ đang ngồi ngoài trời.	Hai người phụ nữ đứng bên ngoài một thư viện.
4	Ayodhya, kinh đô của vua Rama, được nhắc đến trên bờ sông Sarayu.	Ramayana đề cập rằng thành phố Ayodhya nằm trên bờ sông Sarayu.

---

bảng 10

Cặp	Câu 1 (S1)	Câu 2 (S2)
1	IBM chưa chuyển trọng tâm từ máy tính lớn sang cạnh tranh với Windows.	Trong 3 năm, IBM không quan tâm đến máy tính cá nhân.
2	Tôi muốn xem cảnh Quinn nói rằng anh ấy yêu Blay.	Tôi muốn xem cảnh Quinn xin phép bố của Blay để cầu hôn Blay.
3	Jeremy đang rất cần một mái ấm ổn định.	Đồ đạc gồm một chiếc giường xếp, ghế đẩu và một cái bô.
4	Khó đấy. Cả hai đều tuyệt vời.	Câu hỏi này khó thật, cả hai đều tuyệt vời!

A.8.2. Ghi chú (A3)

Hai câu trong Cặp 1 đều đề cập đến IBM và chiến lược kinh doanh của công ty này. Chúng tôi cho rằng cặp này có mối liên hệ chặt chẽ hơn Cặp 3, vì nội dung cụ thể và chia sẻ nhiều chi tiết chung hơn.

B. Các mô hình được huấn luyện trước được sử dụng

Các mô hình HuggingFace được huấn luyện trước được sử dụng trong thí nghiệm bao gồm:

1. mBERT
2. XLM-R
3. AfroXLMR
4. ALBERT

5. AmRoBERTa
6. ARBERT
7. ARB-BERT
8. BETO
9. DziriBERT
10. Indic-BERT
11. MARBERT
12. RoBERTa-BNE
13. HauRoBERTa
14. LaBSE

Ngôn ngữ	**Cơ bản (Base)**	**Tinh chỉnh (Finetuned)**
afr	0.76	0.79
amh	0.79	0.85
arb	0.55	0.62
arq	0.40	0.60
ary	0.38	0.77
eng	0.82	0.83

esp	0.65	0.70
hau	0.48	0.69
hin	0.71	0.77
ind	0.53	0.50
kin	0.45	0.72
mar	0.82	0.88
tel	0.80	0.82

Bảng 12: Hệ số tương quan Spearman trên các mô hình LaBSE (So sánh giữa mô hình Cơ bản và mô hình đã Tinh chỉnh)

Ngôn ngữ	**Cơ bản (Base)**	**Tinh chỉnh (Finetuned)**
afr	0.76	0.79
amh	0.79	0.85
arb	0.55	0.62

arq	0.40	0.60
ary	0.38	0.77
eng	0.82	0.83
esp	0.65	0.70
hau	0.48	0.69
hin	0.71	0.77
ind	0.53	0.50
kin	0.45	0.72
mar	0.82	0.88
tel	0.80	0.82

Bảng 13: Hệ số tương quan Spearman của chỉ số BERTScore với mBERT và XLMR trên các ngôn ngữ khác nhau

---

1. Ngôn ngữ: Telugu (tel)
Câu 1: Đã có thông tin xác nhận việc Dhoni nói lời chia tay với thể thức Test cricket.
Câu 2: Trước đó, bảy người đã thiệt mạng và 12 người bị thương trong một vụ tai nạn giao thông khác.
Điểm tương đồng: 0.02 (Không liên quan)

2. Ngôn ngữ: Afrikaans (afr)

Câu 1: Lời khuyên đầu tiên của tôi là bạn hãy thực tế về khoảng cách mà bạn muốn câu cá.
Câu 2: Điều này đặt dấu chấm hết cho chương trình thám hiểm mặt trăng của Hoa Kỳ.
Điểm tương đồng: 0.19

3. Ngôn ngữ: Tây Ban Nha (esp)
Câu 1: Chi phí tiền tệ để duy trì lò vi sóng là 6 đô la.
Câu 2: Chúng tôi vẫn còn hơn 200.000 đô la cần quyên góp từ những người ủng hộ và nhà tài trợ như bạn.
Điểm tương đồng: 0.27

4. Ngôn ngữ: Marathi (mar)
Câu 1: Chính phủ Thackeray sẽ có 25 bộ trưởng nội các.
Câu 2: Do đó, sự chú ý của mọi người đang đổ dồn vào những gì Raj Thackeray sẽ phát biểu tại buổi tụ họp lễ Gudi Padwa.
Điểm tương đồng: 0.42

5. Ngôn ngữ: Ả Rập Algeria (arq)
Câu 1: Có một câu đối trong bài hát của anh ấy mà bạn có thể biết.
Câu 2: "Kẻ không cảm thấy niềm vui trong thế giới này là kẻ trống rỗng tâm hồn" [một câu đối].
Điểm tương đồng: 0.50

6. Ngôn ngữ: Ả Rập chuẩn (arb)
Câu 1: Giờ đây, tôi sẽ đưa các bạn lướt qua lịch sử kinh tế, theo quan điểm của tôi thì nó có thể hữu ích.
Câu 2: Vào khoảng năm 1850, săn bắt cá voi là một trong những ngành công nghiệp lớn nhất tại Hoa Kỳ.
Điểm tương đồng: 0.62

7. Ngôn ngữ: Hindi (hin)
Câu 1: Số người chết do virus Corona trong nước đã vượt quá 100, với 26 người mất mạng trong 12 giờ qua.
Câu 2: Sự tàn phá của virus Corona đang gia tăng nhanh chóng trong nước.
Điểm tương đồng: 0.72

Tiếp
8. Ngôn ngữ: Kinyarwanda (kin)
Câu 1: Hãy cùng học cách viết tiếng Kinyarwanda cho chuẩn. Trong văn viết tiếng Kinyarwanda, thường hay mắc lỗi viết liền hoặc tách rời các từ sai quy cách.
Câu 2: Hãy cùng thực hành viết tiếng Kinyarwanda cho tốt (phần ba). Trong văn viết tiếng Kinyarwanda, có những từ đi liền với nhau và những từ khác thì tách rời.
Điểm tương đồng: 0.75

9. Ngôn ngữ: Ả Rập Morocco (ary)

Câu 1: Hãy chuẩn bị cho tháng Ramadan, nhiệt độ sẽ bắt đầu ở mức 37 độ ở những vùng này.
Câu 2: Kể từ tháng Ramadan, thời tiết rất nóng. Nhiệt độ đang tăng lên và sẽ đạt tới 40 độ ở những vùng này.
Điểm tương đồng: 0.75

10. Ngôn ngữ: Indonesia (ind)
Câu 1: Giáo dục Làng Pusaka có 4 trường học.
Câu 2: Giáo dục Làng Serumpun Buluh có 4 trường học.
Điểm tương đồng: 0.83

11. Ngôn ngữ: Amharic (amh)
Câu 1: Không có mối liên hệ nào với vấn đề này
Câu 2: Không có gì liên quan đến vấn đề này cả.
Điểm tương đồng: 0.89

12. Ngôn ngữ: Hausa (hau)
Câu 1: Đó là những gì ông ấy nói trong bài phát biểu kỷ niệm 61 năm ngày độc lập của Nigeria.
Câu 2: Ông ấy đã đưa ra khẳng định này trong bài phát biểu mừng lễ độc lập lần thứ 61 của Nigeria vào thứ Sáu.
Điểm tương đồng: 0.94

13. Ngôn ngữ: Anh (eng)
Câu 1: Tôi đã tìm kiếm khắp cả tu viện vì bạn.
Câu 2: Tôi đang tìm bạn ở khắp tu viện.
Điểm tương đồng: 1.00 (Hoàn toàn đồng nghĩa)